



PROYEK AKHIR

**PENGEMBANGAN *DASHBOARD REAL-TIME*
UNTUK *MONITORING* DAN PREDIKSI
KUALITAS UDARA DI KOTA SURABAYA**

**Muhammad Yusuf Rajabiyah
NRP. 3322600020**

DOSEN PEMBIMBING

**Ronny Susetyoko, S.Si., M.Si.
NIP. 197112111995011001**

**Isbat Uzzin Nadhori, S.Kom., M.T.
NIP. 197405052003121002**

**PROGRAM STUDI SARJANA TERAPAN
SAINS DATA TERAPAN
DEPARTEMEN TEKNIK INFORMATIKA DAN
KOMPUTER**

**POLITEKNIK ELEKTRONIKA NEGERI SURABAYA
2026**

PROYEK AKHIR

**PENGEMBANGAN *DASHBOARD REAL-TIME*
UNTUK *MONITORING* DAN PREDIKSI
KUALITAS UDARA DI KOTA SURABAYA**

Muhammad Yusuf Rajabiyah

NRP. 3322600020

DOSEN PEMBIMBING:

Ronny Susetyoko, S.Si., M.Si.

NIP. 197112111995011001

Isbat Uzzin Nadhori, S.Kom., M.T.

NIP. 197405052003121002

**PROGRAM STUDI SARJANA TERAPAN
SAINS DATA TERAPAN
DEPARTEMEN TEKNIK INFORMATIKA DAN
KOMPUTER**

POLITEKNIK ELEKTRONIKA NEGERI SURABAYA

2026

HALAMAN PENGESAHAN

PENGEMBANGAN DASHBOARD REAL-TIME UNTUK MONITORING DAN PREDIKSI KUALITAS UDARA DI KOTA SURABAYA

Oleh:

Muhammad Yusuf Rajabiyah

NRP. 3322600020

**Proyek Akhir ini digunakan sebagai salah satu syarat untuk
memperoleh Gelar Sarjana Terapan Sains Data Terapan (S.Tr.S.D.T.)
di Politeknik Elektronika Negeri Surabaya
2026**

Disetujui oleh:

Pembimbing 1 : Ronny Susetyoko, S.Si., M.Si. ()
NIP. 197112111995011001
Pembimbing 2 : Isbat Uzzin Nadhori, S.Kom., M.T. ()
NIP. 197405052003121002

Penguji 1 : Dr. Edi Satriyanto, S.Si., M.Si. ()
NIP. 197009281995011001
Penguji 2 : Fitrah Maharani Humaira, M.Kom ()
NIP. 198906202022032008

Mengetahui,

Ketua Program Studi Sarjana Terapan Sains Data Terapan
Politeknik Elektronika Negeri Surabaya

Isbat Uzzin Nadhori, S.Kom., M.T.
NIP. 197405052003121002

PERNYATAAN ORISINALITAS

Dengan ini saya menyatakan bahwa bagian atau keseluruhan proyek akhir ini:

1. Adalah hasil karya sendiri dan tidak mengandung unsur plagiat dari pihak lain,
2. Tidak pernah diajukan untuk mendapatkan gelar akademis pada suatu Perguruan Tinggi,
3. Tidak pernah dipublikasikan atau ditulis oleh pihak lain
4. Mencantumkan rujukan dan kutipan dengan jujur dan benar terhadap sumber referensi lain yang menunjang pembahasan pada proyek akhir ini.

Apabila ditemukan bukti bahwa pernyataan saya di atas tidak benar, maka saya bersedia menerima sanksi sesuai dengan ketentuan yang berlaku di Politeknik Elektronika Negeri Surabaya.

Surabaya, 7 Juni 2026

Muhammad Yusuf Rajabiyah
NRP. 3322600020

PERNYATAAN PENGALIHAN HAK CIPTA

Dengan ini, saya yang bertanda tangan di bawah ini:

Nama : Muhammad Yusuf Rajabiyah

NRP : 3322600020

Judul Proyek Akhir : “Pengembangan *Dashboard Real-Time* untuk *Monitoring* dan Prediksi Kualitas Udara Di Kota Surabaya”

Tanggal : 7 Juni 2026

menyatakan bahwa saya selaku penulis (dan/atau mewakili seluruh penulis) secara sadar dan sukarela mengalihkan hak cipta (*copyright*) atas proyek akhir tersebut kepada Politeknik Elektronika Negeri Surabaya.

Demikian pernyataan ini saya buat dengan sebenar-benarnya dan tanpa paksaan dari pihak mana pun.

Hormat saya,

[Materai]

Muhammad Yusuf Rajabiyah

ABSTRAK

Peningkatan pesat urbanisasi, pertumbuhan sektor perindustrian, dan kepadatan transportasi di Kota Surabaya secara langsung berkontribusi signifikan pada degradasi kualitas udara ekstrem, khususnya melalui paparan partikulat debu halus dan polusi emisi gas buang yang membahayakan kesehatan masyarakat. Untuk mengatasi permasalahan tersebut dan menjawab keterbatasan sistem pemantauan konvensional yang umumnya bersifat statis serta murni menyajikan data historis, proyek akhir ini mengembangkan sebuah sistem cerdas berupa *Dashboard Real-Time* Terpadu untuk Monitoring dan Prediksi Kualitas Udara. Arsitektur sistem ini mengintegrasikan perangkat keras akuisisi data berfrekuensi tinggi (perekaman per menit) menggunakan perangkat *Internet of Things* (IoT) berbasis mikrokontroler ESP32 dengan sensor lingkungan *low-cost*, yang disandingkan bersama data meteorologi sekunder resmi dari BMKG. Alur pemrosesan data (*data pipeline*) diperkuat oleh implementasi teknologi *Edge Functions* berbasis *cron job* pada infrastruktur *database cloud* Supabase untuk melakukan agregasi ter-materialisasi secara otomatis, sehingga stabilitas beban komputasi dan responsivitas visualisasi antarmuka web tetap terjaga dengan sangat baik.

Pembaruan utama (*novelty*) dari sistem ini terletak pada arsitektur pemodelan klasifikasi yang minimalis dan berfokus pada ketahanan sistem (*robustness*). Algoritma *Random Forest* berskala 500 pohon keputusan (*trees*) diimplementasikan murni sebagai lapisan ketahanan (*robustness layer*) untuk menstabilkan keputusan (*boundary smoothing*) dari fluktuasi pembacaan sensor IoT. Model dilatih secara langsung menggunakan 5 parameter konsentrasi polutan mentah (PM2.5, PM10, CO, NO₂, dan O₃ dalam satuan $\mu\text{g}/\text{m}^3$ tanpa rekayasa fitur tambahan, dan secara proaktif diinjeksi dengan gangguan data (*noise injection*) sebesar 10% pada fase pelatihan. Berdasarkan evaluasi *drift test* menggunakan *dataset* riil lapangan, pemodelan ini terbukti tangguh mempertahankan tingkat akurasi aktual sebesar 82,3% dengan nilai F1-Score Makro 68,1% di bawah skenario anomali sensor, memvalidasinya sebagai instrumen peringatan dini (*early warning*) yang stabil dan tidak mudah goyah oleh kerusakan kalibrasi perangkat.

Dalam pengujian proyeksi temporal, *XGBoost* secara konsisten mampu menekan akumulasi kesalahan prediksi yang diukur menggunakan metrik *Mean Absolute Percentage Error* (MAPE) di bawah ambang batas sangat akurat untuk seluruh parameter polutan target, yaitu PM2.5 sebesar 7,50%, PM10 sebesar 9,00%, dan karbon monoksida (CO) sebesar 6,36%. Capaian analitik ini secara empiris mengungguli performa pemodelan komparatif *LightGBM* dan metode dekomposisi statistik konvensional *Prophet* yang justru mengalami kegagalan adaptasi (*severe underfitting*) terhadap riak fluktuasi per-menit, dengan tingkat kesalahan melonjak hingga 59,39% pada gas CO. Keseluruhan hasil pengujian secara menyeluruh memvalidasi bahwa ekosistem cerdas ini sangat layak, efisien, dan responsif untuk diimplementasikan sebagai alat pendukung keputusan mitigasi lingkungan kota secara proaktif.

Kata Kunci: Kualitas Udara, Peramalan Real-Time, XGBoost, Random Forest, *Robustness Layer*, Internet of Things

ABSTRACT

The rapid increase in urbanization, industrial sector growth, and transportation density in Surabaya City significantly contributes to extreme air quality degradation, particularly through exposure to fine particulate matter and vehicle exhaust emissions that endanger public health. To address this issue and overcome the limitations of conventional monitoring systems, which are generally static and purely present historical data, this final project develops an intelligent system in the form of an Integrated Real-Time Air Quality Monitoring and Prediction Dashboard. The system architecture integrates high-frequency data acquisition hardware (per-minute recording) utilizing an ESP32 microcontroller-based Internet of Things (IoT) device with low-cost environmental sensors, coupled with official secondary meteorological data from BMKG. The data pipeline is reinforced by the implementation of cron job-based Edge Functions technology on the Supabase cloud database infrastructure to perform automatic materialized aggregation, ensuring the stability of computational loads and the visual responsiveness of the web interface.

The primary novelty of this system lies in its minimalistic and robustness-oriented classification modeling architecture. A Random Forest algorithm consisting of 500 decision trees is implemented purely as a robustness layer to stabilize decision boundaries against fluctuations in IoT sensor readings. The model is trained directly using five raw pollutant concentration parameters (PM_{2.5}, PM₁₀, CO, NO₂, and O₃ in units of $\mu\text{g}/\text{m}^3$) without additional feature engineering, and is proactively exposed to 10% noise injection during the training phase. Based on drift test evaluations using real-world field datasets, the model demonstrated strong resilience by maintaining an actual accuracy of 82.3% and a Macro F1-Score of 68.1% under sensor anomaly scenarios, validating its effectiveness as a stable early warning instrument that is resistant to calibration disturbances and sensor degradation.

In temporal projection testing, XGBoost consistently suppressed the accumulation of predictive errors, measured using the Mean Absolute Percentage Error (MAPE) metric, below the highly accurate threshold for all target pollutant parameters: 7.50% for PM_{2.5}, 9.00% for PM₁₀, and 6.36% for carbon monoxide (CO). This analytical achievement empirically outperformed the comparative modeling of LightGBM and the conventional statistical decomposition method Prophet, which conversely experienced severe underfitting towards per-minute fluctuation ripples, with its error rate surging to 59.39% for CO gas. The overall comprehensive test results validate that this intelligent ecosystem is highly feasible, efficient, and responsive to be implemented as a proactive decision-support tool for urban environmental mitigation.

Keywords: Air Quality, Real-Time Forecasting, XGBoost, Random Forest, Robustness Layer, Internet of Things

KATA PENGANTAR

Puji syukur penulis panjatkan kehadirat Allah SWT yang telah melimpahkan rahmat, hidayah, serta karunia-Nya, sehingga penulis dapat menyelesaikan Buku Proyek Akhir yang berjudul “Pengembangan Dashboard Real-Time untuk Monitoring dan Prediksi Kualitas Udara di Kota Surabaya” dengan baik. Proyek Akhir ini disusun sebagai salah satu syarat akademis wajib guna memperoleh gelar Sarjana Terapan Sains Data Terapan (S.Tr.S.D.T.) pada Program Studi Sarjana Terapan Sains Data Terapan, Departemen Teknik Informatika dan Komputer, Politeknik Elektronika Negeri Surabaya.

Dalam proses pelaksanaan penelitian, akuisisi data sensor, hingga penyusunan laporan ini, penulis telah banyak menerima bantuan, bimbingan, fasilitas, serta dukungan moral maupun material dari berbagai pihak. Oleh karena itu, pada kesempatan ini penulis ingin menyampaikan apresiasi dan ucapan terima kasih yang sebesar-besarnya kepada:

1. Tuhan Yang Maha Esa yang telah melimpahkan kemudahan kepada penulis sejak dalam pelaksanaan proyek akhir ini sampai dengan penyusunan laporan proyek akhir.
2. Bapak Dr.-Ing. Ir. Arif Irwansyah, S.T., M.Eng. selaku Direktur Politeknik Elektronika Negeri Surabaya yang telah memberikan dukungan dan fasilitas selama masa perkuliahan.
3. Bapak Ronny Susetyoko, S.Si., M.Si., selaku Dosen Pembimbing 1 yang senantiasa memberikan arahan ilmiah, koreksi mendalam, dan masukan konstruktif demi kesempurnaan penelitian ini.
4. Bapak Isbat Uzzin Nadhori, S.Kom., M.T., selaku Ketua Program Studi Sarjana Terapan Sains Data Terapan sekaligus Dosen Pembimbing 2 yang telah memberikan arahan, ilmu, waktu, dan bimbingan yang sangat berharga bagi penulis selama penyusunan Proyek Akhir ini.
5. Bapak Prof. M. Udin Harun Al Rasyid, S.Kom., Ph.D, selaku Kepala Departemen Teknik Informatika dan Komputer yang telah memberikan dukungan dan fasilitas selama masa perkuliahan.
6. Pemilik Warung Kopi Sedulur Tunggal Kopi Ngagel dan UPN, yang telah memberikan izin tempat, bantuan fasilitas, serta keramahan yang luar biasa selama penulis melakukan proses penempatan perangkat IoT dan pengambilan sampel data spasial kualitas udara di titik pemantauan Ngagel dan sekitar kampus UPN.

7. Pemilik Warung Kopi Cak Betik, yang telah memberikan dukungan fasilitas dan izin lokasi yang memadai, sehingga penulis dapat melaksanakan proses akuisisi data parameter polutan lingkungan di lapangan secara lancar dan kondusif.
8. Pihak Pengelola Transportasi Publik Wira Wiri Suroboyo, atas penyediaan sarana transportasi dan aksesibilitas pergerakan yang mendukung mobilitas penulis dalam melakukan survei lokasi dan analisis spasial karakteristik kualitas udara lalu lintas urban di Kota Surabaya.
9. Rekan-rekan mahasiswa D4 Sains Data Terapan PENS Angkatan 2022.
10. Semua pihak yang tidak dapat disebutkan satu per satu atas dukungan bantuan, dan doanya selama penyusunan Proyek Akhir ini.

Penulis menyadari bahwa laporan Proyek Akhir ini masih jauh dari kesempurnaan. Oleh karena itu, kritik dan saran yang membangun sangat penulis harapkan demi perbaikan di masa mendatang. Akhir kata, semoga laporan ini dapat memberikan manfaat nyata bagi perkembangan ilmu pengetahuan, khususnya di bidang Sains Data, serta berkontribusi positif bagi pengelolaan lingkungan Kota Surabaya

DAFTAR ISI

ABSTRAK	vi
ABSTRACT	viii
DAFTAR ISI	xii
DAFTAR GAMBAR	xvi
DAFTAR TABEL	xvii
BAB 1	1
PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Permasalahan	3
1.3 Tujuan	3
1.4 Batasan Masalah	3
1.5 Manfaat	4
1.6 Sistematika Penelitian	5
BAB 2	7
KAJIAN PUSTAKA	7
2.1 Deskripsi Permasalahan	7
2.2 Teori Penunjang	8
2.2.1 Kualitas Udara dan Indikatornya	8
2.2.2 Internet of Things (IoT) untuk Pemantauan Lingkungan	9
2.2.3 Algoritma <i>Machine Learning</i> untuk Prediksi Kualitas Udara	10
2.2.4 XGBoost (eXtreme Gradient Boosting)	10
2.2.5 LightGBM (Light Gradient Boosting Machine)	13
2.2.6 Prophet	15
2.2.7 Random Forest	17
2.2.8 Integrasi Data dan Pengembangan <i>Dashboard</i> Analitik	18
2.2.9 Analisis Varians (ANOVA) dan Uji Asumsi	19
2.3 Penelitian Terkait	19
2.3.1 Penelitian Prediksi Kualitas Udara dengan <i>Machine Learning</i>	20
2.3.1.1 Air Quality Forecasting Using <i>Machine learning</i> : Comparative Analysis and Ensemble Strategies for Enhanced Prediction	20
2.3.1.2 Performance of <i>machine learning</i> models to forecast PM10 levels	20
2.3.1.3 XGBoost: A scalable tree boosting system	21
2.3.2 Pencemaran Udara Akibat Emisi Gas Buang Kendaraan Bermotor	22

2.3.3 Pemantauan Kualitas Udara.....	22
2.3.4 Implementasi Internet of Things (IoT) Dalam Monitoring Kualitas Udara Pada Ruang Terbuka.....	22
2.3.5 Pemantauan Kualitas Udara Berbasis Internet of Things.....	22
BAB 3.....	25
DESKRIPSI SISTEM	25
3.1 Deskripsi Solusi.....	25
3.2 Perancangan Sistem.....	26
3.2.1 Perangkat Keras dan Sumber Data	26
3.2.2 Proses Pengambilan Data (Data Acquisition)	27
3.2.3 Proses Penyimpanan Backend (Supabase Backend)	27
3.2.4 Proses Pengolahan dan Peramalan Data (Data Processing & Forecasting).....	27
3.2.5 Tahapan Pembuatan Model	28
3.2.5.1 Identifikasi Fitur dan Target	28
3.2.5.2 Pembersihan dan Transformasi Data	29
3.2.5.3 Pembagian Data: Pelatihan dan Pengujian	30
3.2.5.4 Pelatihan Model	30
3.2.5.5 Penggunaan Model Stabilisasi Keputusan dan Peramalan	31
3.2.5.6 Penggunaan Model Peramalan.....	32
3.2.5.7 Evaluasi Kinerja Model	34
3.2.5.8 Horizon Peramalan 60 Menit	35
3.2.6 Implementasi Backend dan Logika Pemrosesan Data.....	35
3.2.6.1 Otomasi Pemrosesan Data Terjadwal	37
3.2.7 Proses Pembuatan Dashboard.....	37
3.2.8 Perencanaan Pengambilan Sampel dan Analisis Spasial Kualitas Udara.....	38
3.2.8.1 Pengambilan Sampel Data Spasial.....	38
3.2.8.2 Analisis Data Spasial	39
3.2.8.3 Interpretasi Hasil Analisis	40
3.3 Desain Mockup	40
3.3.1 Dashboard Overview	41
3.3.2 Data Cuaca BMKG dan Tren Polutan	42
3.3.3 Prediksi Kualitas Udara dengan Model <i>Machine Learning</i>	43
BAB 4.....	45
HASIL PENELITIAN.....	45
4.1 Parameter Eksperimen.....	45

4.2 Karakteristik Data	46
4.3 Lokasi Uji Coba	47
4.4 Waktu Uji Coba.....	47
4.5 Spesifikasi Peralatan Uji Coba.....	48
4.6 Implementasi Arsitektur Sistem untuk Agregasi Data.....	48
4.6.1 Implementasi <i>Ingestion Data</i> dan Perangkat IoT	49
4.6.2 Spesifikasi dan Karakteristik Data	49
4.6.2.1 Mekanisme Pengiriman Data ke Backend	50
4.6.2.2 Payload Data Konsentrasi Gas dan Lingkungan.....	50
4.7 Hasil Eksperimen	51
4.7.1 Pengambilan Data dari Database.....	51
4.7.2 Preprocessing Data	51
4.7.3 Analisis Eksplorasi Data (EDA).....	52
4.7.3.1 Karakteristik dan Ringkasan Statistik.....	52
4.7.3.2 Analisis Tren Temporal dan Distribusi Polutan.....	53
4.7.3.3 Analisis Pola Diurnal (Harian) Polutan	54
4.7.4 Analisis Hubungan Antar Variabel (Korelasi)	55
4.7.4.1 Matriks Korelasi Pearson.....	55
4.7.4.2 Analisis Korelasi Silang (<i>Cross-Correlation Function</i> - CCF)	55
4.7.5 Uji Stasioneritas dan Analisis Autokorelasi	56
4.7.5.1 Uji Stasioneritas (Augmented Dickey-Fuller)	56
4.7.5.2 Analisis ACF dan PACF Multi-Polutan	57
4.7.6 Hasil Implementasi Model Peramalan.....	58
4.7.6.1 Implementasi Model XGBoost	58
4.7.6.2 Implementasi Model LightGBM.....	60
4.7.6.3 Implementasi Model Prophet.....	61
4.7.6.4 Perbandingan Performa Ketiga Model.....	62
4.7.7 Implementasi Model Klasifikasi ISPU	63
4.7.7.1 Implementasi Model Random Forest sebagai <i>Robustness Layer</i>	63
4.7.7.2 Implementasi Model Pembanding dan Pengujian Ketahanan (<i>Drift Test</i>)	64
4.7.7.3 Alasan Pemilihan Random Forest.....	65
4.7.7.4 Perhitungan ISPU dan Penetapan Polutan Dominan	65
4.7.8 Hasil Aplikasi Dashboard Web	66
4.7.8.1 Tampilan Overview	66
4.7.8.2 Tampilan Hasil Prediksi.....	70

4.7.9 Hasil Pengambilan Sampel dan Analisis Klasifikasi Kualitas Udara.....	73
4.7.9.1 Pengambilan Sampel Data Spasial.....	73
4.7.9.2 Perbandingan Distribusi Label Antar Wilayah	75
4.7.9.3 Statistik Deskriptif Hasil Pengukuran Kualitas Udara.....	76
4.7.9.4 Studi Kasus Analisis Spasial menggunakan Uji ANOVA.....	78
BAB 5.....	81
PENUTUP	81
5.1 Kesimpulan.....	81
5.2 Saran.....	82
DAFTAR PUSTAKA	83
LAMPIRAN	87

DAFTAR GAMBAR

Gambar 2.1 Contoh Tampilan Dashboard Berbasis Web	19
Gambar 3.1 Desain Sistem	26
Gambar 3.2 Blok Diagram Sistem	27
Gambar 3.3 Struktur Tabel Data Mentah	35
Gambar 3.4 Struktur Tabel Data Agregasi	36
Gambar 3.5 Alur Agregasi Otomatis.....	36
Gambar 3.6 Riwayat Eksekusi Agregasi Cron Job	37
Gambar 3.7 Mock-Up Metrics Card	42
Gambar 3.8 Mock-Up Integrasi Data Bmkg	43
Gambar 3.9 Mock-Up Hasil Prediksi	44
Gambar 4.1 Alur Data Ingestion	49
Gambar 4.2 Detail Logs Pengambilan Data	51
Gambar 4.3 Hasil Preprocessing	52
Gambar 4.4 Visualisasi Time Series	53
Gambar 4.5 Visualisasi Rolling Mean	53
Gambar 4.6 Histogram Sebaran Polutan	54
Gambar 4.7 Boxplot Pola Harian	54
Gambar 4.8 Korelasi Pearson.....	55
Gambar 4.9 Visualisasi Cross Correlation Function.....	56
Gambar 4.10 Visualisasi ACF Dan PACF	57
Gambar 4.11 Tampilan Halaman Overview	66
Gambar 4.12 Tampilan Klasifikasi Kualitas Udara	67
Gambar 4.13 Tampilan Metric Card	67
Gambar 4.14 Panel Infomasi Tambahan	68
Gambar 4.15 Pola Harian Data Teragregasi.....	68
Gambar 4.16 Distribusi PM2.5 Pada Jam Sibuk.....	69
Gambar 4.17 Trend Data Agregasi	69
Gambar 4.18 Heatmap Kalender Kontribusi Pm2.5	70
Gambar 4.19 Sebaran Data CO ISPU	70
Gambar 4.20 Halaman Forecast	71
Gambar 4.21 Prediksi Kualitas Udara.....	71
Gambar 4.22 Peramalan PM 2.5 Dalam 1 Jam	72
Gambar 4.23 Peramalan PM10 Dalam 1 Jam	72

DAFTAR TABEL

Tabel 2.1 Kategori Indeks Pencemaran Udara	9
Tabel 2.2 Penelitian Terkait	23
Tabel 3.1 Fitur Dan Target Untuk Model	29
Tabel 3.2 Titik Koordinat Lokasi Pengambilan Sampel Spasial	39
Tabel 4.1 Hyperparameter Model Xgboost.....	45
Tabel 4.2 Hyperparameter Model Lightgbm.....	46
Tabel 4.3 Parameter Model Prophet.....	46
Tabel 4.4 Karakteristik Dataset.....	47
Tabel 4.5 Spesifikasi Peralatan Uji Coba.....	48
Tabel 4.6 Ringkasan Statistik Data	52
Tabel 4.7 Hasil Uji ADF	56
Tabel 4.8 Parameter Terbaik Model Xgboost	59
Tabel 4.9 Metrik Evaluasi Model Xgboost	59
Tabel 4.10 Parameter Terbaik Model Lightgbm.....	60
Tabel 4.11 Metrik Evaluasi Model Lightgbm.....	61
Tabel 4.12 Metrik Evaluasi Model Prophet	61
Tabel 4.13 Perbandingan Metrik Evaluasi Ketiga Model	62
Tabel 4.14 Spesifikasi Model.....	63
Tabel 4.15 Komparasi Evaluasi Ketahanan Model Terhadap Fluktuasi Sensor	64
Tabel 4.16 Distribusi Label Tiap Wilayah	76
Tabel 4.17 Statistik Deskriptif PM2.5.....	77
Tabel 4.18 Statistik Deskriptif PM10.....	77
Tabel 4.19 Statistik Deskriptif CO.....	78
Tabel 4.20 Ringkasan Hasil Uji One-Way Anova	79

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Peningkatan pesat urbanisasi dan industrialisasi telah menyebabkan degradasi kualitas udara parah, menjadi ancaman serius bagi kesehatan manusia dan ekosistem, serta mempercepat perubahan iklim global. Polusi udara ini, jika tidak ditangani, dapat menghambat kemajuan pencapaian Tujuan Pembangunan Berkelanjutan (*Sustainable Development Goals*). Kota Surabaya, sebagai pusat ekonomi dan industri terbesar kedua, menghadapi krisis masalah ini. Pertumbuhan pesat sektor otomotif dan industri secara signifikan meningkatkan konsentrasi emisi polutan, di mana emisi transportasi terbukti menjadi penyumbang pencemaran udara tertinggi di perkotaan, mencapai sekitar 80%[1]. Peningkatan kadar partikel debu halus (PM_{2.5}), nitrogen dioksida (NO₂), dan sulfur dioksida (SO₂) diketahui menyebabkan gangguan pernapasan, penurunan kualitas hidup, dan memperparah tekanan terhadap ekosistem perkotaan.

Selain dipicu oleh tingginya volume emisi transportasi dan industri, tingkat konsentrasi polutan di udara perkotaan juga sangat dipengaruhi oleh faktor meteorologis lokal. Parameter fisik seperti suhu dan kelembapan udara memainkan peran penting dalam perilaku dispersi serta akumulasi polutan. Sebagai contoh, suhu yang tinggi dapat mempercepat laju reaksi kimia pembentuk polutan sekunder seperti ozon, sementara tingkat kelembapan memengaruhi visibilitas dan sedimentasi massa partikulat seperti PM_{2.5} dan PM₁₀. Oleh karena itu, informasi cuaca resmi dari BMKG diintegrasikan ke dalam antarmuka sistem murni sebagai data pendukung pada *dashboard monitoring*. Integrasi data meteorologi ini bertujuan untuk memberikan konteks kondisi lingkungan sekitar secara komprehensif bagi pengguna dalam mengamati tren kualitas udara[2]. Sebagai bentuk validasi dan studi kasus tambahan atas sistem yang dibangun, penelitian ini juga melakukan analisis komparatif spasial secara *purposive* di area dengan tata guna lahan yang berbeda, seperti area lalu lintas perkotaan, titik pemantauan industri manufaktur, dan pusat logistik. Pendekatan tambahan ini bertujuan untuk melihat kapabilitas model analitik dalam merespons pola fluktuasi emisi polutan yang bervariasi di luar titik pemantauan utama.

Untuk menjawab permasalahan tersebut dan mengatasi keterbatasan sistem pemantauan konvensional yang umumnya bersifat historis serta tidak prediktif, proyek akhir ini mengusulkan pengembangan Dashboard Pemantauan dan Prediksi Kualitas Udara Berbasis Web *Real-time* yang dirancang khusus untuk Kota Surabaya. Sistem ini akan mengintegrasikan

data dari sensor IoT lokal dan data sekunder resmi dari BMKG untuk menyediakan informasi kualitas udara secara dinamis. Selain itu, dashboard ini dilengkapi dengan perhitungan Indeks Standar Pencemar Udara (ISPU) deterministik yang diperkuat oleh algoritma *machine learning* sebagai lapisan ketahanan (*robustness layer*) terhadap *noise* sensor, serta model prediksi untuk memperkirakan kondisi kualitas udara pada waktu mendatang. Pendekatan ini sangat dibutuhkan mengingat kualitas udara di Indonesia, khususnya di kota-kota besar, seringkali berada pada tingkat tidak sehat; laporan IQAir (2024) menunjukkan bahwa rata-rata konsentrasi PM2.5 di banyak wilayah perkotaan Indonesia melebihi ambang batas aman WHO, menempatkan Indonesia sebagai salah satu negara dengan tingkat polusi udara tinggi di Asia Tenggara[3]. Keefektifan pendekatan ini juga telah dibuktikan oleh studi lain seperti Bekkar et al. (2024) yang berhasil mengembangkan platform AIoT *real-time* untuk monitoring dan prediksi kualitas udara menggunakan sensor *low-cost* dan *machine learning* [4] serta penelitian yang menunjukkan bahwa kombinasi IoT dengan *machine learning* secara signifikan meningkatkan akurasi dan efisiensi sistem pemantauan kualitas udara dibanding metode tradisional [5].

Dalam aspek analitik, pendekatan *machine learning* digunakan untuk melakukan pemodelan dan prediksi kualitas udara berdasarkan parameter polutan dan variabel pendukung lainnya. Model utama yang diterapkan dalam penelitian ini adalah *Extreme Gradient Boosting* (XGBoost). Algoritma XGBoost dipilih sebagai model utama karena keunggulannya yang sangat baik dalam menangani hubungan non-linear yang kompleks antara variabel polutan dan faktor meteorologi, memiliki fungsi regularisasi eksplisit yang efektif untuk mencegah *overfitting*, serta terbukti menghasilkan akurasi tinggi pada berbagai studi prediksi kualitas udara. Untuk keperluan evaluasi dan perbandingan kinerja, model *Light Gradient Boosting Machine* (LightGBM) yang unggul dalam efisiensi komputasi serta metode statistik Prophet digunakan sebagai model pembanding.

Pemodelan prediksi dilakukan untuk memperkirakan nilai parameter kualitas udara secara simultan, khususnya pada variabel PM2.5, PM10, dan CO serta Indeks Standar Pencemar Udara (ISPU) pada horizon waktu 60 menit ke depan berdasarkan data historis. Pendekatan berbasis *machine learning*, khususnya XGBoost dan LightGBM, dinilai lebih adaptif dan konsisten dibandingkan metode konvensional yang murni berbasis statistik karena mampu menangkap hubungan kompleks antar variabel lingkungan. Sementara itu, Prophet digunakan sebagai *baseline* prediksi deret waktu yang berfokus pada komponen tren dan musiman. Dengan memanfaatkan XGBoost sebagai pilar utama arsitektur analitik, sistem dapat

menghasilkan peramalan yang lebih andal dan presisi, sehingga informasi kualitas udara dapat disajikan secara informatif untuk mendukung pemantauan berbasis data berbasis *real-time*.

Pengembangan sistem ini juga melibatkan kolaborasi dengan mahasiswa Teknik Elektronika dalam pemanfaatan dan pengelolaan modul sensor IoT yang telah tersedia. Diharapkan, hasil proyek akhir ini dapat menjadi dasar pengambilan kebijakan berbasis data dalam upaya mitigasi dampak pencemaran udara dan perubahan iklim secara lebih efektif.

1.2 Permasalahan

Berdasarkan latar belakang yang diuraikan dan fokus proyek, permasalahan utama yang ingin diatasi dalam proyek ini adalah sebagai berikut:

1. Minimnya sistem monitoring kualitas udara yang mampu mengakuisisi, mengintegrasikan, dan menyajikan data kualitas udara secara *real-time* dari lingkungan lokal Kota Surabaya.
2. Belum optimalnya pemanfaatan algoritma *machine learning* untuk klasifikasi serta prediksi kualitas udara berbasis data lokal Surabaya.
3. Belum tersedianya sistem pendukung keputusan yang mampu menginterpretasikan hasil monitoring dan prediksi kualitas udara menjadi informasi yang mudah dipahami untuk mendukung perencanaan dan kebijakan lingkungan.

1.3 Tujuan

Adapun tujuan yang ingin dicapai melalui proyek akhir ini adalah sebagai berikut:

1. Mengembangkan antarmuka web yang interaktif untuk eksplorasi dan visualisasi data kualitas udara *real-time*.
2. Mengimplementasikan algoritma *XGBoost* untuk PM2.5, PM10, dan CO dengan horizon waktu 60 menit ke depan serta implementasi algoritma *Random Forest* sebagai lapisan ketahanan (*robustness layer*) yang bertujuan meredam efek gangguan (*noise*) pada sensor IoT dan menstabilkan keputusan klasifikasi kualitas udara.
3. Mengembangkan fitur analisis dan sistem pendukung keputusan yang memanfaatkan hasil monitoring, klasifikasi, dan prediksi kualitas udara untuk membantu pengambilan kebijakan lingkungan dan mitigasi risiko pencemaran udara.

1.4 Batasan Masalah

Agar pembahasan dan pengembangan sistem dalam Proyek Akhir ini lebih terarah dan tidak menyimpang dari tujuan awal, maka ditetapkan batasan-batasan masalah sebagai berikut:

1. Penelitian ini berfokus pada analisis data kualitas udara dan pemodelan prediktif (peramalan dan klasifikasi). Penelitian tidak membahas atau melakukan analisis diagnostik secara mendalam terhadap performa arsitektur perangkat keras (*hardware*).
2. Pengumpulan data dilakukan menggunakan perangkat mikrokontroler ESP32 dengan sensor kategori *low-cost* (seperti sensor GP2Y1010AU0F). Perangkat ini difungsikan murni sebagai alat akuisisi data indikatif, bukan ditujukan sebagai kalibrator standar atau pengganti stasiun pemantau kualitas udara referensi milik pemerintah.
3. Implementasi sistem pemantauan secara *real-time* dan pengiriman data kontinu ke *database cloud* (Supabase) difokuskan pada satu titik pemantauan statis. Adapun pengambilan sampel data spasial di tiga lokasi lain (Ngagel, Rungkut, dan Margomulyo) hanya bersifat temporal sebagai studi kasus tambahan untuk keperluan uji komparatif ANOVA, dan tidak diintegrasikan sebagai *node* sensor *real-time* permanen.
4. Pemodelan analitik dibatasi pada dua metodologi utama: (1) pemodelan *forecasting* untuk memprediksi nilai konsentrasi polutan (PM2.5, PM10, dan CO) hingga 60 menit ke depan menggunakan algoritma *XGBoost* atau *LightGBM*, serta (2) Pemodelan klasifikasi dirancang menggunakan pendekatan minimalis, di mana input fitur secara ketat dibatasi pada 5 nilai konsentrasi polutan mentah (PM2.5, PM10, CO, NO₂, dan O₃) dalam satuan $\mu\text{g}/\text{m}^3$ tanpa rekayasa fitur lanjutan (seperti rasio ISPU). Evaluasi kinerja model difokuskan pada uji ketahanan (*drift test*) terhadap anomali data, bukan sekadar akurasi pada data bersih.
5. Hasil akhir dari sistem berupa *dashboard* pemantauan berbasis *web* yang berfungsi untuk menampilkan visualisasi data hasil *monitoring*, metrik statistik, serta hasil prediksi dari model *machine learning* yang telah dikembangkan.

1.5 Manfaat

Proyek akhir ini diharapkan dapat memberikan beberapa manfaat signifikan bagi berbagai pihak, antara lain:

- **1.5.1 Bagi Masyarakat Umum:**

- Meningkatkan akses informasi kualitas udara yang teragregasi secara *real-time* dan prediktif, sehingga individu dapat mengambil keputusan yang lebih baik terkait aktivitas harian dan kesehatan, seperti membatasi aktivitas di luar ruangan saat kualitas udara buruk.

- **1.5.2 Bagi Pemerintah dan Pemangku Kepentingan :**

- Menyediakan data terintegrasi dan hasil klasifikasi otomatis bagi pemangku kebijakan seperti Dinas Lingkungan Hidup Kota Surabaya untuk mendukung perumusan kebijakan lingkungan yang lebih tepat sasaran, seperti regulasi emisi dan perencanaan tata kota.
- Mendukung pengambilan keputusan yang lebih cepat dan responsif oleh pemerintah daerah serta Kementerian Lingkungan Hidup dan Kehutanan dalam penanganan isu kualitas udara, termasuk penyampaian peringatan dini kepada masyarakat.

- **1.5.3 Bagi Komunitas dan Akademisi (Mahasiswa, Kampus, Peneliti):**

- Menjadi sumber data teragregasi, model prediksi yang valid dan terbuka untuk penelitian lebih lanjut di bidang kualitas udara, *machine learning*, *deep learning*, dan *Internet of Things*.
- Mendorong transparansi data melalui dashboard analitik yang mudah diakses, memfasilitasi partisipasi aktif komunitas dalam upaya pemantauan dan peningkatan kualitas lingkungan.
- Berfungsi sebagai studi kasus dan platform pembelajaran bagi mahasiswa di bidang Teknik Informatika dan Teknik Elektronika.

- **1.5.4 Bagi Sektor Industri dan Transportasi:**

- Menyediakan data objektif mengenai kontribusi dan dampak operasional mereka terhadap kualitas udara, sehingga dapat mendorong praktik operasional yang lebih ramah lingkungan dan bertanggung jawab.

1.6 Sistematika Penelitian

Penulisan laporan proyek akhir ini disusun secara sistematis dalam beberapa bab, yaitu:

BAB 1 PENDAHULUAN

Bab ini menjelaskan latar belakang masalah, perumusan masalah, tujuan yang ingin dicapai, manfaat yang diharapkan, serta ruang lingkup dan batasan masalah dari proyek akhir ini.

BAB 2 KAJIAN PUSTAKA

Bab ini menyajikan landasan teori dan kajian pustaka yang relevan, mencakup teori tentang kualitas udara dan parameter pencemar, teknologi Internet of Things (IoT),

pemodelan *Robustness Layer* klasifikasi dengan Random Forest serta metode peramalan menggunakan XGBoost, LightGBM, dan model deret waktu seperti Prophet. Juga dibahas penelitian-penelitian terdahulu sebagai pembanding dan penguat kontribusi proyek ini.

BAB 3 DESKRIPSI SISTEM

Bab ini menguraikan secara rinci solusi yang ditawarkan, desain sistem secara keseluruhan, perancangan perangkat keras, komunikasi data antar perangkat IoT dan server cloud, proses pengolahan data, analisis, dan visualisasi. Selain itu, dijelaskan pula tahapan pembuatan model klasifikasi dan prediksi, serta evaluasi kinerjanya menggunakan metrik statistik.

BAB 4 HASIL PENELITIAN

Bab ini menyajikan hasil eksperimen dan pembahasan terhadap sistem monitoring dan prediksi kualitas udara yang telah dikembangkan. Pembahasan mencakup hasil akuisisi data kualitas udara secara real-time dari sensor PM2.5, PM10, CO, suhu, dan kelembapan, serta analisis pola data yang diperoleh. Selain itu, dilakukan evaluasi kinerja model peramalan menggunakan beberapa metode yang telah diimplementasikan, dengan penilaian berbasis metrik statistik untuk mengukur akurasi dan keandalan model. Hasil peramalan dan klasifikasi kemudian divisualisasikan melalui Dashboard Web, sehingga memungkinkan pemantauan kondisi kualitas udara secara informatif dan mudah dipahami oleh pengguna.

BAB 5 PENUTUP

Bab ini berisi kesimpulan dari seluruh proses perancangan, implementasi, dan pengujian sistem monitoring dan prediksi kualitas udara berbasis Dashboard Web, serta rencana pengembangan di masa mendatang. Pengembangan selanjutnya diarahkan pada penambahan data temporal dan parameter pencemar tambahan, peningkatan kualitas klasifikasi menggunakan model *machine learning* yang lebih teruji, serta pengembangan sistem alert dan rekomendasi berbasis prediksi yang ditujukan untuk mendukung pengambilan keputusan, khususnya bagi pemangku kebijakan dalam pengelolaan kualitas udara.

BAB 2

KAJIAN PUSTAKA

2.1 Deskripsi Permasalahan

Kualitas udara merupakan isu lingkungan global yang semakin mendesak, terutama di area perkotaan yang padat akibat pesatnya urbanisasi dan industrialisasi. Kota-kota besar seperti Surabaya menghadapi masalah serius terkait peningkatan konsentrasi polutan udara, yang berasal dari berbagai sumber seperti emisi kendaraan bermotor dan aktivitas industri. Tingginya kadar polutan ini tidak hanya berdampak negatif pada kesehatan masyarakat, memicu berbagai penyakit pernapasan dan kardiovaskular, tetapi juga berkontribusi pada degradasi lingkungan dan perubahan iklim lokal.

Permasalahan pada sistem pemantauan kualitas udara saat ini adalah keterbatasannya dalam menyediakan informasi yang bersifat prediktif dan real-time secara terpadu. Data kualitas udara umumnya hanya ditampilkan dalam bentuk data historis dari titik pemantauan tertentu, tanpa adanya mekanisme untuk memperkirakan kondisi kualitas udara pada waktu mendatang. Akibatnya, informasi yang tersedia belum sepenuhnya mendukung kebutuhan pemantauan yang bersifat antisipatif, baik bagi masyarakat maupun pihak terkait, sehingga potensi peningkatan risiko kesehatan akibat paparan polutan tidak dapat direspon secara lebih dini.

Keterbatasan tersebut menjadi semakin signifikan jika dikaitkan dengan kondisi faktual di Indonesia, di mana pertumbuhan sektor transportasi dan industri berlangsung sangat pesat. Peningkatan aktivitas ini berkontribusi langsung terhadap tingginya emisi polutan udara. Ismiyati et al. (2014) dalam penelitiannya menyatakan bahwa sekitar 80% udara yang tercemar berasal dari emisi transportasi [1]. Hal ini mengindikasikan bahwa tanpa pemantauan dan intervensi yang efektif, masalah polusi udara akan terus memburuk.

Selain itu, pemanfaatan teknologi canggih seperti *machine learning* (ML) dan *deep learning* (DL) untuk analisis mendalam, klasifikasi status kualitas udara secara otomatis, dan prediksi di masa depan, masih belum optimal terintegrasi dalam sistem pemantauan lokal. Keterbatasan ini menghambat upaya mitigasi dan adaptasi yang efektif terhadap dampak polusi udara dan korelasinya dengan indikator perubahan iklim. Kondisi ini menuntut pengembangan solusi inovatif yang mampu memberikan informasi kualitas udara secara *real-time*, prediktif, dan mendukung pengambilan keputusan yang lebih baik.

2.2 Teori Penunjang

Penelitian ini menggunakan berbagai teori dan metode terkait sebagai dasar pengembangan sistem dalam mengatasi permasalahan yang diidentifikasi.:

2.2.1 Kualitas Udara dan Indikatornya

Penelitian ini mendefinisikan kualitas udara sebagai kondisi udara yang diukur berdasarkan parameter fisik, kimia, dan biologis. Menurut Ismiyati et al. (2014) [1], kualitas udara yang baik merupakan kondisi udara dengan konsentrasi partikel dan polutan yang rendah sehingga tidak menimbulkan risiko kesehatan. Parameter polutan udara utama yang relevan dalam konteks perkotaan meliputi Particulate Matter (PM_{2.5}, PM₁₀), Karbon Monoksida (CO), Nitrogen Dioksida (NO₂), dan Ozon (O₃).

Di Indonesia, Kementerian Lingkungan Hidup dan Kehutanan menggunakan Indeks Standar Pencemar Udara (ISPU) untuk menggambarkan mutu udara ambien. KLHK memanfaatkan ISPU sebagai indikator berbasis dampak kesehatan, estetika, dan ekosistem. KLHK juga menggunakan ISPU sebagai sistem peringatan dini (*early warning system*) untuk masyarakat di daerah rawan terdampak pencemaran udara [6]. KLHK menyusun ISPU untuk memberikan kemudahan dan keseragaman informasi mutu udara ambien kepada publik, serta menjadi bahan pertimbangan bagi pemerintah pusat dan daerah dalam upaya pengendalian pencemaran udara.

KLHK telah menerbitkan Peraturan Menteri Lingkungan Hidup dan Kehutanan Nomor 14 Tahun 2020 tentang Indeks Standar Pencemar Udara, yang menggantikan peraturan sebelumnya. Peraturan ini menetapkan perhitungan ISPU dilakukan berdasarkan tujuh parameter utama: PM₁₀, PM_{2.5}, NO₂, SO₂, CO, O₃, dan Hidrokarbon (HC), dengan penambahan parameter HC dan PM_{2.5} karena risiko kesehatan yang besar. Selain itu, KLHK meningkatkan frekuensi penyampaian informasi ISPU kepada publik, di mana hasil perhitungan ISPU parameter PM_{2.5} disampaikan tiap jam selama 24 jam, sedangkan parameter lainnya disampaikan paling sedikit dua kali sehari pada pukul 09.00 dan 15.00 [7].

Tabel 2.1 Kategori Indeks Pencemaran Udara

Rentang	Kategori	Penjelasan
1-50	Baik	Tingkat mutu udara yang sangat baik, tidak memberikan efek negatif terhadap manusia, hewan, dan tumbuhan.
51-100	Sedang	Tingkat mutu udara masih dapat diterima pada kesehatan manusia, hewan, dan tumbuhan.
101-200	Tidak Sehat	Tingkat mutu udara yang bersifat merugikan pada manusia, hewan dan tumbuhan.
201-300	Sangat Tidak Sehat	Tingkat mutu udara yang dapat meningkatkan resiko kesehatan pada sejumlah segmen populasi yang terpapar
301+	Berbahaya	Tingkat mutu udara yang dapat merugikan kesehatan serius pada populasi dan perlu penanganan cepat.

Perhitungan ISPU dilakukan berdasarkan nilai batas atas dan batas bawah ISPU serta konsentrasi ambien hasil pengukuran. Persamaan matematis perhitungan ISPU adalah sebagai berikut [6]:

$$I = \frac{I_a - I_b}{X_a - X_b} (X_x - X_b) + I_b$$

(2.1)

Keterangan:

- I = ISPU terhitung
- Ia = ISPU batas atas
- Ib = ISPU batas bawah
- Xa = Konsentrasi ambien batas atas ($\mu\text{g}/\text{m}^3$)
- Xb = Konsentrasi ambien batas bawah ($\mu\text{g}/\text{m}^3$)
- Xx = Konsentrasi ambien nyata hasil pengukuran ($\mu\text{g}/\text{m}^3$)

2.2.2 Internet of Things (IoT) untuk Pemantauan Lingkungan

Internet of Things (IoT) menghubungkan objek fisik dengan sensor, perangkat lunak, dan jaringan komunikasi untuk mengumpulkan serta bertukar data secara otomatis. Dalam pemantauan lingkungan, IoT memungkinkan pengumpulan data dari sensor yang tersebar

secara *real-time* dan otomatis, mengatasi batasan geografis dan biaya pemantauan tradisional [8], [9]. Komponen utama sistem IoT meliputi sensor untuk akuisisi data, mikrokontroler untuk pemrosesan lokal, modul komunikasi nirkabel, dan platform *cloud* untuk penyimpanan serta visualisasi data.

2.2.3 Algoritma *Machine Learning* untuk Prediksi Kualitas Udara

Prediksi kualitas udara telah menjadi area penelitian yang aktif dengan penerapan berbagai algoritma *machine learning*. Chen et al. (2025) dan Tırink (2025) menunjukkan bahwa model berbasis gradient boosting dan time series forecasting memberikan hasil yang baik dalam menangkap pola kompleks konsentrasi polutan udara.

2.2.4 XGBoost (eXtreme Gradient Boosting)

XGBoost adalah algoritma gradient boosting yang dikembangkan oleh Chen dan Guestrin pada tahun 2016, dioptimalkan untuk kecepatan dan performa tinggi. Model ini menjadi salah satu algoritma paling populer dalam kompetisi *machine learning* dan aplikasi praktis karena kemampuannya menghasilkan prediksi yang sangat akurat [10]. XGBoost membangun *ensemble* dari *decision tree* secara sekuensial. Model melatih setiap *tree* baru untuk memperbaiki kesalahan dari model sebelumnya dengan menggunakan prinsip *gradient descent* guna meminimalkan fungsi *loss*. Proses optimasi tersebut dinyatakan dalam persamaan berikut:

$$L(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k)$$

(2.2)

Keterangan:

- $L(\phi)$: total *loss* yang diminimalkan (gabungan kesalahan dan kompleksitas model)
- $l(\hat{y}_i, y_i)$: fungsi *loss* untuk mengukur selisih prediksi dan nilai aktual
- $\Omega(f_k)$: fungsi regularisasi untuk mengontrol kompleksitas model
- f_k : *decision tree* ke-k dalam *ensemble*
- $\hat{y}_i$: nilai prediksi untuk sampel ke-i
- y_i : nilai aktual untuk sampel ke-i

Persamaan tersebut menunjukkan bahwa XGBoost tidak hanya meminimalkan kesalahan prediksi, tetapi juga mengontrol kompleksitas model melalui regularisasi.

Selanjutnya, XGBoost mendefinisikan fungsi regularisasi untuk menghindari overfitting sebagai berikut:

$$\Omega(f) = \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2 \quad (2.3)$$

Keterangan:

- $\Omega(f)$: fungsi penalti untuk kompleksitas model
- γ : parameter pengontrol jumlah leaves
- T : jumlah leaves dalam tree
- λ : parameter regularisasi L2
- w_j : bobot pada leaf ke-j

Persamaan ini menunjukkan bahwa model memberikan penalti terhadap struktur tree yang terlalu kompleks untuk menghasilkan model yang lebih sederhana dan stabil.

XGBoost juga menggunakan *Taylor expansion* orde kedua untuk memperoleh aproksimasi fungsi *loss* yang lebih akurat. Pendekatan ini dinyatakan dalam persamaan berikut:

$$L^t \approx \sum_{i=1}^n \left[l(y_i, \hat{y}_i^{(t-1)}) + g_i f_t(x_i) + \frac{1}{2} h_i f_t^2(x_i) \right] + \Omega(f_t) \quad (2.4)$$

Keterangan:

- L^t : nilai *loss* pada iterasi ke-t
- $l(y_i, \hat{y}_i^{(t-1)})$: *loss* dari prediksi sebelumnya
- g_i : turunan pertama (*gradient*)
- h_i : turunan kedua (*Hessian*)
- $f_t(x_i)$: *tree* baru pada iterasi ke-t
- $\Omega(f_t)$: regularisasi untuk *tree* baru

Pendekatan ini memungkinkan model mempercepat proses konvergensi dan meningkatkan akurasi prediksi.

Dalam proses pembentukan *tree*, XGBoost melakukan *pruning* untuk mengontrol kompleksitas model. Model menghitung nilai *gain* untuk setiap kemungkinan *split* menggunakan persamaan berikut:

$$Gain = \frac{1}{2} \left[\frac{G_L^2}{H_L + \lambda} + \frac{G_R^2}{H_R + \lambda} - \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} \right] - \gamma$$

(2.5)

Keterangan:

- Gain: peningkatan kualitas model setelah *split*
- G_L, G_R : jumlah *gradient* pada node kiri dan kanan
- H_L, H_R : jumlah *Hessian* pada node kiri dan kanan
- λ : parameter regularisasi L2
- γ : batas minimum *gain* untuk melakukan *split*

Persamaan tersebut menunjukkan bahwa model hanya melakukan *split* jika menghasilkan peningkatan performa yang signifikan.

XGBoost menerapkan dua jenis regularisasi untuk mencegah *overfitting*. Model menggunakan regularisasi L1 (*Lasso*) untuk mendorong sparsity pada bobot sehingga membantu *feature selection*. Selain itu, model menggunakan regularisasi L2 (*Ridge*) untuk membatasi nilai bobot agar tidak terlalu besar sehingga menghasilkan model yang lebih stabil.

Özüpak et al. (2025) dalam penelitiannya mencapai hasil kinerja yang baik dengan XGBoost, memperoleh koefisien determinasi sebesar 0.9994, *mean absolute error* sebesar 0.0120, dan *mean squared error* sebesar 0.0005 untuk prediksi kualitas udara. Hasil ini menunjukkan kemampuan yang baik XGBoost dalam menangkap dinamika spasial dan temporal polusi udara dengan akurasi yang sangat tinggi, hampir mendekati perfect prediction [11]. Oblitas & Escobedo (2024) dalam studi kasusnya di Lima, Peru, menunjukkan bahwa XGBoost mencapai akurasi tinggi tanpa perbedaan statistik signifikan dibanding LightGBM, dengan kemampuan robust menangani variasi meteorologi dan polutan. Paired t-test mengkonfirmasi bahwa performa kedua model comparable untuk prediksi PM2.5 dan PM10 pada kondisi optimal [12].

XGBoost mengimplementasikan dua jenis regularization untuk mencegah overfitting. Regularisasi L1 atau Lasso dengan parameter alpha mendorong sparsity pada weights, sedangkan regularisasi L2 atau Ridge dengan parameter lambda mencegah weights yang terlalu besar.

Dalam penelitian ini, XGBoost digunakan sebagai model utama untuk peramalan kualitas udara karena kemampuannya menangani hubungan non-linear yang kompleks antara variabel polutan dan faktor meteorologi, regularisasi eksplisit yang efektif mencegah overfitting, serta performa yang sangat tinggi pada berbagai studi prediksi kualitas udara.

2.2.5 LightGBM (Light Gradient Boosting Machine)

LightGBM adalah framework gradient boosting yang dikembangkan oleh Microsoft pada tahun 2017, dirancang khusus untuk efisiensi dan performa tinggi pada *dataset* berskala besar. Model ini dikembangkan oleh Ke et al. (2017) [4] menggunakan pendekatan berbasis decision tree dengan strategi pertumbuhan leaf-wise yang unik, berbeda dari algoritma boosting tradisional yang menggunakan pendekatan *level-wise*. Keunggulan utama LightGBM terletak pada kemampuannya memproses data dalam jumlah besar dengan kecepatan tinggi sambil tetap mempertahankan akurasi prediksi yang akurat, LightGBM memiliki beberapa karakteristik unggulan yang membuatnya efektif untuk prediksi kualitas udara. Pertama, teknik histogram-based splitting digunakan untuk membagi data kontinu menjadi bins diskrit, yang secara signifikan mengurangi waktu komputasi dan penggunaan memori, sebagaimana dijelaskan oleh Özüpak et al. (2025) [11]. Proses ini memungkinkan algoritma untuk menangani *dataset* berukuran besar tanpa memerlukan resource komputasi yang berlebihan.

Kedua, LightGBM mengimplementasikan strategi pertumbuhan leaf-wise, di mana algoritma memilih leaf dengan loss maksimum untuk diperluas. Pendekatan ini berbeda dengan algoritma lain yang menggunakan *level-wise growth*, dan menghasilkan model yang lebih akurat dengan jumlah iterasi yang sama. Liu et al. (2023) menjelaskan bahwa strategi ini memungkinkan model untuk fokus pada area yang paling memerlukan perbaikan, menghasilkan efisiensi yang lebih tinggi dalam proses pelatihan [13].

Ketiga, teknik Gradient-based One-Side Sampling (GOSS) diterapkan untuk meningkatkan efisiensi tanpa mengorbankan akurasi. GOSS mempertahankan semua instances dengan gradien besar sambil melakukan random sampling pada instances dengan gradien kecil, sebagaimana dijelaskan oleh Hajihosseini et al. (2023) [14]. Teknik ini memungkinkan model untuk fokus pada data yang paling informatif sambil mengurangi beban komputasi.

Keempat, Exclusive Feature Bundling (EFB) digunakan untuk menggabungkan fitur-fitur yang saling eksklusif, mengurangi dimensi data dan mempercepat proses pelatihan menurut Zhang et al. (2023) [15]. Teknik ini sangat berguna ketika berhadapan dengan *dataset* yang memiliki banyak fitur, seperti data meteorologi dan polutan dalam prediksi kualitas udara. Fungsi objektif LightGBM dihitung menggunakan formula sebagai berikut:

$$L = \sum_{i=1}^N l(y_i, \hat{y}_i) + \Omega(f)$$

(2.6)

Keterangan:

- L : nilai fungsi objektif.
- N : jumlah sampel data pelatihan.
- l : fungsi loss.
- y_i : nilai aktual sampel ke- i .
- $\hat{y}_i$: nilai prediksi sampel ke- i .
- $\Omega(f)$: fungsi regularisasi.

Model additive yang digunakan dalam LightGBM dapat diformulasikan sebagai:

$$y_i^{(m)} = \widehat{y_i^{(m-1)}} + \nu \cdot f_m(x_i)$$

(2.7)

Keterangan:

- $\hat{y}_i^{(m)}$: prediksi pada iterasi ke- m .
- $\hat{y}_i^{(m-1)}$: prediksi pada iterasi sebelumnya.
- ν : learning rate.
- $f_m(x_i)$: weak learner pada iterasi ke- m .
- x_i : vektor fitur sampel ke- i .

Penelitian oleh Liu et al. (2023) menunjukkan bahwa LightGBM mampu memprediksi konsentrasi PM2.5 dengan akurasi tinggi, mendemonstrasikan strong learning capability, high degree of fit, serta peningkatan signifikan dalam akurasi dan stabilitas[13]. Model ini terbukti sangat efektif dalam menangani hubungan nonlinear kompleks antara variabel meteorologi dan konsentrasi polutan. Kemampuan ini sangat penting karena interaksi antara faktor-faktor seperti suhu, kelembapan, kecepatan angin, dan emisi polutan seringkali bersifat nonlinear dan sulit dimodelkan dengan pendekatan statistik tradisional. Mampitiya et al. (2023) melaporkan bahwa LightGBM mencapai akurasi tinggi untuk prediksi PM10 di Sri Lanka, menunjukkan adaptabilitas model terhadap kondisi geografis yang berbeda [16].

LightGBM memiliki beberapa karakteristik unggulan yang membuatnya efektif untuk prediksi kualitas udara. Pertama, teknik histogram-based splitting digunakan untuk membagi data kontinu menjadi bins diskrit, yang secara signifikan mengurangi waktu komputasi dan penggunaan memori. Kedua, LightGBM mengimplementasikan strategi pertumbuhan leaf-wise, di mana algoritma memilih leaf dengan loss maksimum untuk diperluas. Ketiga, teknik Gradient-based One-Side Sampling (GOSS) diterapkan untuk meningkatkan efisiensi tanpa mengorbankan akurasi.

Dalam penelitian ini, LightGBM digunakan sebagai model pembanding untuk mengevaluasi performa model utama XGBoost dalam melakukan peramalan konsentrasi polutan udara. Meskipun LightGBM memiliki keunggulan dalam kecepatan komputasi, hasil penelitian menunjukkan bahwa XGBoost memberikan performa yang lebih tinggi untuk data kualitas udara dengan fluktuasi tinggi.

2.2.6 Prophet

Prophet adalah tool forecasting time series yang dikembangkan oleh Facebook, sekarang Meta, pada tahun 2017 oleh Taylor dan Letham, dirancang khusus untuk menangani data dengan seasonality kuat dan efek holiday. Model ini menggunakan pendekatan decomposable additive model yang intuitif dan mudah diinterpretasi, membuatnya accessible tidak hanya untuk data scientists tetapi juga untuk domain experts tanpa latar belakang statistik yang mendalam. Prophet mengimplementasikan model additive dengan formula:

$$y(t) = g(t) + s(t) + h(t) + \epsilon_t$$

(2.8)

Keterangan:

- $y(t)$: nilai prediksi pada waktu t .
- $g(t)$: komponen tren.
- $s(t)$: komponen musiman (seasonality).
- $h(t)$: komponen hari libur atau peristiwa khusus.
- ϵ_t : kesalahan residual.

Trend component dalam Prophet dapat dimodelkan dengan dua pendekatan. Untuk pertumbuhan yang saturating atau memiliki carrying capacity, digunakan logistic growth model dengan formula:

$$g(t) = \frac{C(t)}{1 + \exp(-k(t - m))}$$

(2.9)

Keterangan:

- $C(t)$: carrying capacity.
- k : laju pertumbuhan.
- t : variabel waktu.
- m : parameter offset.

.

Untuk pertumbuhan linear, digunakan piecewise linear model:

$$g(t) = (k + a(t)^T \delta)t + (m + a(t)^T \gamma)$$

(2.10)

Keterangan:

- k : baseline growth rate.
- $a(t)$: vektor indikator changepoint.
- δ : vektor perubahan laju pertumbuhan.
- m : baseline offset.
- γ : vektor penyesuaian offset.

Seasonality component dimodelkan menggunakan Fourier series untuk menangkap periodic patterns:

$$s(t) = \sum_{n=1}^N \left(a_n \cos\left(\frac{2\pi nt}{P}\right) + b_n \sin\left(\frac{2\pi nt}{P}\right) \right)$$

(2.11)

Keterangan:

- N : jumlah komponen Fourier.
- P : periode seasonality.
- a_n : koefisien sinus.
- b_n : koefisien cosinus.
- t : variabel waktu.

Holiday component menangkap efek dari special events:

$$h(t) = \sum_{i=1}^L \kappa_i \cdot \mathbb{1}_{[t \in D_i]}$$

(2.12)

Keterangan:

- L : jumlah hari libur yang digunakan.
- κ_i : pengaruh hari libur ke- i .
- D_i : himpunan tanggal hari libur ke- i .
- $\mathbb{1}(t \in D_i)$: fungsi indikator.

Chen et al. (2025) menggunakan Prophet untuk prediksi PM2.5 di Nanning, China, dan menemukan bahwa model ini memiliki keunggulan dalam menangani *seasonality* dan *trend data* konsentrasi polutan dengan *interpretability* yang tinggi [17]. Meskipun Prophet menunjukkan performa baik dalam menangkap pola *seasonal regular* dengan koefisien determinasi berkisar 0.78 hingga 0.89, model ini memiliki keterbatasan dalam menangani kompleksitas perubahan konsentrasi pada periode Mei-Juli di mana terjadi perubahan meteorologi yang rapid dan unpredictable. Penelitian menunjukkan Prophet efektif untuk beberapa aplikasi spesifik. Pertama, prediksi jangka panjang dengan *seasonal pattern* yang jelas seperti variasi tahunan konsentrasi PM2.5 yang dipengaruhi oleh perbedaan musim. Kedua, menangani *missing data* dan *outliers* secara *robust* melalui *built-in mechanisms* tanpa *preprocessing* ekstensif. Ketiga, memberikan *uncertainty intervals* yang informatif melalui Bayesian approach yang membantu *decision making*. Keempat, analisis pengaruh *events* khusus seperti *holiday* atau masa liburan terhadap kualitas udara yang relevan untuk *urban planning*.

2.2.7 Random Forest

Random Forest adalah algoritma ensemble learning yang dikembangkan oleh Leo Breiman pada tahun 2001, yang membangun banyak decision trees secara paralel dan menggabungkan hasil voting untuk menghasilkan prediksi final. Algoritma ini dikenal karena kemampuannya dalam menangani data dengan dimensi tinggi, ketahanan terhadap overfitting, dan kemampuan feature importance yang membantu memahami kontribusi masing-masing variabel terhadap hasil prediksi. Mampitiya et al. (2024) menyatakan bahwa stabilitas

klasifikasi Random Forest pada data multivariat menjadikannya pilihan optimal untuk sistem pemantauan lingkungan yang membutuhkan respons cepat [16].

Dalam sistem pemantauan kualitas udara berbasis IoT, kelemahan utama dari penentuan status udara yang murni berbasis aturan kaku (*rule-based ISPU*) adalah kerentanannya terhadap fluktuasi di batas ambang kategori (*boundary*) dan penurunan performa kalibrasi sensor seiring waktu (*drift*). Oleh karena itu, algoritma *Random Forest* diaplikasikan bukan untuk menggantikan rumus ISPU secara deterministik, melainkan difungsikan sebagai instrumen stabilisasi keputusan (*boundary smoothing*).

Pada praktiknya, ketahanan *Random Forest* dibangun melalui metode *noise injection* selama fase pelatihan, di mana data input konsentrasi polutan sengaja diberikan gangguan acak (misalnya sebesar 10%). Pendekatan ini memaksa kumpulan pohon keputusan (*trees*) untuk tidak menghafal pola data yang bersih, melainkan melatih sistem untuk mengenali sinyal bahaya yang sebenarnya meskipun data sensor terkorupsi. Keandalan arsitektur ini tidak diukur dari akurasi murni, melainkan menggunakan metrik *drift test*, yaitu simulasi persentase anomali lingkungan untuk memastikan sistem tetap memberikan peringatan dini (*early warning*) yang stabil saat perangkat keras mengalami disfungsi parsial.

2.2.8 Integrasi Data dan Pengembangan *Dashboard* Analitik

Integrasi data melibatkan penggabungan informasi dari berbagai sumber ke dalam satu platform yang kohesif. Tantangannya meliputi penanganan format data yang heterogen, frekuensi data yang berbeda, dan validasi data untuk memastikan akurasi. Sebuah *dashboard* analitik berbasis web akan menjadi antarmuka utama untuk menyajikan data yang terintegrasi secara *real-time*, hasil klasifikasi, dan proyeksi prediksi. Desain *dashboard* ini harus mengedepankan visualisasi data yang intuitif dan interaktif untuk memudahkan pemangku kepentingan dalam eksplorasi data, pemahaman tren, dan pengambilan keputusan yang berbasis data. Contoh Tampilan *Dashboard* berbasis Web ditunjukkan pada gambar berikut ini.



Gambar 2.1 Contoh Tampilan Dashboard berbasis Web

2.2.9 Analisis Varians (ANOVA) dan Uji Asumsi

Analysis of Variance (ANOVA) satu arah (One-Way ANOVA) adalah metode statistik inferensial parametrik yang digunakan untuk menguji probabilitas perbedaan nilai rata-rata yang signifikan di antara tiga atau lebih kelompok eksperimen independen. Menurut Walpole et al. (2016) [18], uji ANOVA membandingkan variansi di dalam kelompok sampel terhadap variansi antar kelompok dengan memanfaatkan distribusi statistik. Keandalan metode ini sangat bergantung pada pemenuhan dua asumsi dasar parametrik, yaitu asumsi normalitas residual yang dievaluasi menggunakan uji Shapiro-Wilk, serta asumsi homogenitas varians populasi yang diukur melalui Levene's Test. Apabila nilai probabilitas (p-value) dari pengujian bernilai lebih kecil dibandingkan tingkat signifikansi yang ditetapkan, maka hipotesis nol ditolak, yang membuktikan bahwa setidaknya terdapat satu kelompok dengan nilai rata-rata yang berbeda secara nyata.

Meskipun menuntut pemenuhan asumsi, ANOVA tergolong tangguh (robust) terhadap penyimpangan normalitas ringan berkat Teorema Limit Pusat (Walpole et al., 2016) [18]. Apabila ANOVA terbukti signifikan, analisis wajib dilanjutkan dengan uji komparasi Post-hoc Tukey HSD untuk memetakan secara spesifik pasangan lokasi mana yang memiliki perbedaan secara nyata.

2.3 Penelitian Terkait

Bagian ini memuat ulasan mengenai penelitian-penelitian terdahulu yang memiliki permasalahan serupa dengan proyek ini, namun menggunakan pendekatan atau fokus yang berbeda, sehingga menegaskan orisinalitas dan kontribusi proyek yang diusulkan.

2.3.1 Penelitian Prediksi Kualitas Udara dengan *Machine Learning*

Berbagai penelitian telah dilakukan untuk mengembangkan model prediksi kualitas udara menggunakan algoritma *machine learning*. Penelitian-penelitian ini menunjukkan evolusi dan peningkatan akurasi dalam prediksi konsentrasi polutan udara.

2.3.1.1 Air Quality Forecasting Using *Machine learning* : Comparative Analysis and Ensemble Strategies for Enhanced Prediction

Özüpak et al. (2025) melakukan penelitian komprehensif tentang prediksi kualitas udara di wilayah urban yang terpolusi menggunakan data dari sensor metal oxide dan analyzer tersertifikasi periode Maret 2004 hingga Februari 2005. Penelitian ini membandingkan 10 model regresi *machine learning* termasuk XGBoost, LightGBM, Random Forest, Gradient Boosting, CatBoost, SVR dengan Bayesian Optimization, Decision Tree, KNN, Elastic Net, dan Bayesian Ridge. Hasil penelitian menunjukkan bahwa model SVR yang dioptimasi dengan Bayesian Optimization mencapai performa tertinggi dengan R^2 sebesar 99.94%, MAE 0.0120, dan MSE 0.0005. Penelitian ini membuktikan bahwa hyperparameter optimization dan strategi ensemble secara signifikan meningkatkan akurasi dalam menangkap dinamika spasial dan temporal polusi udara [11]. Tırınk (2025) melakukan studi prediksi AQI harian di Iğdır, Turki menggunakan data jangka panjang dari tahun 2016 hingga 2024. Penelitian ini membandingkan tiga model *machine learning*: XGBoost, dan LightGBM dengan data polutan (PM2.5, PM10, NO2, O3) dan variabel meteorologi. Dengan menggunakan Bayesian Optimization dan Randomized Cross-Validation untuk hyperparameter tuning, XGBoost mencapai akurasi prediksi tertinggi dengan R^2 sebesar 0.999, RMSE 0.234, dan MAE 0.158 [14]. Hasil ini mendemonstrasikan bahwa model ensemble berbasis XGBoost sangat efektif dalam memodelkan fluktuasi AQI menggunakan prediktor lingkungan, memberikan insights berharga untuk sistem peringatan dini dan manajemen polusi udara regional.

2.3.1.2 Performance of *machine learning* models to forecast PM10 levels

Penelitian yang dilakukan oleh Liu et al. pada tahun 2023 menggunakan model LightGBM untuk memprediksi konsentrasi atmosfer PM2.5 dengan mengoptimalkan parameter model. Setelah menganalisis data monitoring dari berbagai waktu dan wilayah, kurva prediksi konsentrasi kabut menunjukkan bahwa model memiliki strong learning capability, high degree of fit, dan peningkatan signifikan dalam akurasi serta stabilitas. Penelitian ini membuktikan bahwa optimisasi dengan algoritma LightGBM secara signifikan meningkatkan presisi dan sangat applicable dalam praktik untuk forecasting konsentrasi PM2.5 [19].

Mampitiya et al. (2023) melaporkan bahwa LightGBM mencapai akurasi tinggi untuk prediksi PM10 di Sri Lanka, menunjukkan adaptabilitas model terhadap kondisi geografis yang berbeda. Penelitian ini mengonfirmasi bahwa LightGBM tidak hanya efektif di satu lokasi tetapi dapat digeneralisasi ke berbagai konteks geografis dan klimatologis [16].

2.3.1.3 XGBoost: A scalable tree boosting system

Chen et al. (2025) melakukan studi komprehensif tentang prediksi konsentrasi PM2.5 di wilayah urban Nanning, China menggunakan data raster resolusi tinggi CHAP periode 2012-2023 [17]. Penelitian ini melakukan perbandingan sistematis tiga model: SARIMA (statistical time series), Prophet (seasonal & holiday effects), dan LightGBM (*machine learning*) dengan evaluasi menggunakan MSE, MAE, dan R^2 pada dimensi spasial dan temporal.

Hasil penelitian menunjukkan bahwa LightGBM memiliki kemampuan kuat dalam mining hubungan nonlinear kompleks dengan R^2 bulanan berkisar 0.54-0.99, namun stabilitasnya bervariasi. Prophet unggul dalam menangani seasonality dan trend time series dengan R^2 annual 0.78-0.88, tetapi kurang adaptif terhadap perubahan kompleks terutama pada periode Mei-Juli. SARIMA berbasis teori prediksi time series menunjukkan performa baik pada beberapa skenario dengan deviasi overall yang relatif kecil, namun terbatas dalam menangani data non-stationary dan heterogenitas spasial. Penelitian ini menyediakan referensi multi-dimensional untuk prediksi PM2.5 dan membantu pemilihan model sesuai skenario spesifik.

Oblitas & Escobedo (2024) melakukan studi kasus di distrik San Borja, Lima, Peru untuk memprediksi konsentrasi PM2.5 dan PM10 periode Januari-April 2024 menggunakan data SENAMHI. Penelitian ini membandingkan XGBoost dan LightGBM dengan dua skenario: Skenario 1 menggunakan semua variabel meteorologi dan polutan, sedangkan Skenario 2 mengeksklusi PM10 untuk prediksi PM2.5 dan sebaliknya. Evaluasi dilakukan menggunakan R^2 , RMSE, MAE, dan MAPE dengan uji statistik paired t-test.

Hasil menunjukkan bahwa kedua model mencapai akurasi tinggi dengan R^2 lebih dari 0.75 pada Skenario 1, tanpa perbedaan statistik signifikan antara XGBoost dan LightGBM. Namun, eksklusi variabel kunci pada Skenario 2 menghasilkan penurunan akurasi signifikan dengan R^2 turun hingga 0.54-0.69. Temuan ini menunjukkan pentingnya feature selection yang tepat untuk strategi manajemen lingkungan yang efektif dan mengonfirmasi bahwa kedua algoritma memiliki performa comparable pada *dataset* yang sama [12].

2.3.2 Pencemaran Udara Akibat Emisi Gas Buang Kendaraan Bermotor

Penelitian ini menggarisbawahi bahwa emisi transportasi menjadi penyumbang pencemaran udara tertinggi di perkotaan Indonesia, mencapai sekitar 80% [1]. Studi ini berfokus pada analisis dampak dan implikasi kebijakan melalui metode kepustakaan. Namun, lingkup penelitian ini lebih bersifat makro dan teoritis, tanpa melibatkan implementasi sistem monitoring *real-time* berbasis IoT atau penggunaan metode klasifikasi dan prediksi *machine learning*.

2.3.3 Pemantauan Kualitas Udara

Buku ajar ini menyediakan pemahaman fundamental tentang kualitas udara, komponennya, dampaknya, serta berbagai metode pemantauan [20]. Karya ini menjelaskan prinsip-prinsip pemantauan berkelanjutan dan jenis-jenis sistem yang ada, seperti metode pasif, stasiun tetap, dan *drone*. Sebagai sumber teoritis, buku ini tidak mencakup pengembangan atau implementasi sistem *real-time* yang terintegrasi dengan data BMKG atau kemampuan prediksi ML/DL.

2.3.4 Implementasi Internet of Things (IoT) Dalam Monitoring Kualitas Udara Pada Ruang Terbuka

Studi ini berhasil membangun sistem monitoring kualitas udara di ruang terbuka menggunakan teknologi IoT yang terintegrasi dengan Google Sheet [8]. Implementasi ini menunjukkan bahwa sistem yang dikembangkan mampu melakukan pemantauan *real-time* dan efisien dalam mendeteksi variasi parameter kualitas udara. Meskipun relevan dalam aspek IoT dan *real-time*, penelitian ini tidak mencakup integrasi data sekunder dari BMKG, tidak menerapkan algoritma klasifikasi kompleks seperti Random Forest atau XGBoost, dan belum mengembangkan model prediksi kualitas udara secara komprehensif.

2.3.5 Pemantauan Kualitas Udara Berbasis Internet of Things

Penelitian ini mengembangkan alat monitoring kualitas udara berbasis IoT yang menampilkan data *real-time* melalui aplikasi web dan *smartphone* [9]. Proyek ini berfokus pada deteksi polutan gas CO dan debu, serta penyajian data melalui platform seperti Blynk dan ThingSpeak. Kendati sukses dalam menampilkan data *real-time* dari sensor IoT, studi ini belum mengintegrasikan data sekunder dari BMKG, tidak menggunakan algoritma klasifikasi seperti Random Forest atau XGBoost, dan belum mengembangkan model prediksi kualitas udara.

Tabel 2.2 Penelitian Terkait

No.	Judul Penelitian	Objek Penelitian	Metode yang Digunakan	Hasil & Kesimpulan Utama
1	Implementasi Internet Of Things (Iot) dalam Monitoring Kualitas Udara pada Ruang Terbuka	Kualitas udara (CO ₂ , CO, suhu, kelembapan) di ruang terbuka.	Implementasi sistem IoT (ESP32, sensor) terintegrasi dengan Google Sheet.	Sistem IoT dapat melakukan pemantauan <i>real-time</i> dan efisien dalam mendeteksi variasi parameter kualitas udara.
2	Pemantauan Kualitas Udara Berbasis Internet Of Things	Kualitas udara (gas CO, debu, suhu, kelembapan) di lingkungan sekolah (SMP PGRI 1 Ciputat).	Research and Development (R&D), implementasi perangkat keras (WeMos D1 R2s, sensor) dan aplikasi web (ThingSpeak, Blynk).	Sistem monitoring dapat memberikan peringatan dini kualitas udara; data sensor ditampilkan secara <i>real-time</i> melalui web dan smartphone.
3	Optimization of Interval Fuzzy Time Series with Particle Swarm Optimization for Prediction Air Quality on Pekanbaru	Kualitas udara (PM ₁₀ , SO ₂ , CO, O ₃ , NO ₂) di Kota Pekanbaru (data historis).	Metode komputasi (Fuzzy Time Series dioptimasi dengan Particle Swarm Optimization - FTS-PSO).	FTS-PSO cukup akurat (MAPE 18,3583%) untuk prediksi kualitas udara harian.
4	A systematic survey of air quality prediction based on deep learning	Metode prediksi kualitas udara berbasis deep learning.	Studi literatur sistematis (systematic survey).	Deep learning unggul dalam mengidentifikasi pola kompleks dan non-linear pada data kualitas udara; berbagai arsitektur DL efektif untuk prediksi.
5	<i>Real-time</i> AIIoT platform for monitoring and prediction of air quality in Southwestern Morocco	Kualitas udara (PM _{2.5}) di Maroko (menggunakan sensor low-cost).	Implementasi sistem AIIoT, feature selection (mRMR, LightGBM-RFE), optimasi hyperparameter (Bayesian optimization), evaluasi model prediksi (LightGBM).	LightGBM menunjukkan kinerja unggul dalam prediksi PM _{2.5} setelah optimasi fitur dan hyperparameter, menyediakan solusi <i>real-time</i> dan hemat biaya.
6	Air Quality Forecasting Using <i>Machine learning</i> : Comparative Analysis and Ensemble Strategies for Enhanced Prediction	Kualitas udara (PM _{2.5} , NO _x , CO, benzene) di wilayah urban yang terpolusi menggunakan data dari sensor metal oxide dan analyzer tersertifikasi (Maret 2004–Februari 2005).	Perbandingan 10 model regresi ML: XGBoost, LightGBM, Random Forest, Gradient Boosting, CatBoost, SVR dengan Bayesian Optimization, Decision Tree, KNN, Elastic Net, dan Bayesian Ridge; stacking ensemble method.	Model SVR yang dioptimasi dengan Bayesian Optimization mencapai performa tertinggi ($R^2 = 99.94\%$, MAE = 0.0120, MSE = 0.0005). Hyperparameter optimization dan strategi ensemble secara signifikan meningkatkan akurasi dalam menangkap dinamika spasial dan temporal polusi udara.

No.	Judul Penelitian	Objek Penelitian	Metode yang Digunakan	Hasil & Kesimpulan Utama
7	<i>Machine learning</i> -based forecasting of air quality index under long-term environmental patterns: A comparative approach with XGBoost, LightGBM, and SVM	Prediksi AQI harian di Iğdır, Turki (2016–2024) menggunakan data polutan (PM10, SO2, NO2, O3) dan variabel meteorologi.	Perbandingan tiga model ML: XGBoost, LightGBM, dan SVM; hyperparameter optimization dengan Bayesian Optimization dan Randomized CV; evaluasi dengan R ² , RMSE, dan MAE.	XGBoost mencapai akurasi prediksi tertinggi (R ² = 0.999, RMSE = 0.234, MAE = 0.158). Model ensemble berbasis XGBoost efektif memodelkan fluktuasi AQI menggunakan prediktor lingkungan, memberikan insights berharga untuk sistem peringatan dini dan manajemen polusi udara regional.
8	Decoding PM2.5 Prediction in Nanning Urban Area, China: Unraveling Model Superiorities and Drawbacks Through SARIMA, Prophet, and LightGBM	Prediksi konsentrasi PM2.5 di wilayah urban Nanning, China (2012–2023) menggunakan data raster resolusi tinggi CHAP dengan resolusi temporal ganda (tahunan dan bulanan).	Perbandingan sistematis tiga model: SARIMA (statistical time series), Prophet (seasonal & holiday effects), dan LightGBM (<i>machine learning</i>); evaluasi menggunakan MSE, MAE, dan R ² pada dimensi spasial dan temporal.	LightGBM memiliki kemampuan kuat mining hubungan nonlinear kompleks namun stabilitasnya rendah. Prophet unggul dalam menangani seasonality dan trend time series tetapi kurang adaptif terhadap perubahan kompleks. SARIMA berbasis teori prediksi time series, performa baik pada beberapa skenario namun terbatas dalam menangani data non-stationary dan heterogenitas spasial. Penelitian menyediakan referensi multi-dimensional untuk prediksi PM2.5 dan membantu pemilihan model sesuai skenario spesifik.
9	Prediction of PM2.5 and PM10 Concentrations Using XGBoost and LightGBM Algorithms: A Case Study in Lima, Peru	Prediksi konsentrasi PM2.5 dan PM10 di distrik San Borja, Lima, Peru (Januari–April 2024) menggunakan data SENAMHI (polutan dan meteorologi).	Perbandingan XGBoost dan LightGBM dengan dua skenario: S1 (semua variabel meteorologi dan polutan), S2 (eksklusi PM10 untuk prediksi PM2.5 dan sebaliknya); evaluasi dengan R ² , RMSE, MAE, dan MAPE; uji statistik paired t-test.	Kedua model mencapai akurasi tinggi dengan R ² > 0.75 pada S1. Tidak ada perbedaan statistik signifikan antara XGBoost dan LightGBM dalam performa prediksi. Eksklusi variabel kunci (S2) menghasilkan penurunan akurasi signifikan (R ² turun hingga 0.54-0.69), menunjukkan pentingnya feature selection yang tepat untuk strategi manajemen lingkungan yang efektif.

BAB 3

DESKRIPSI SISTEM

3.1 Deskripsi Solusi

Solusi yang ditawarkan dalam proyek akhir ini adalah sistem Dashboard Pemantauan dan Prediksi Kualitas Udara Berbasis Web *Real-Time*, yang secara khusus dirancang untuk menyajikan informasi kualitas udara terkini, data historis, serta hasil prediksi melalui visualisasi yang mudah dipahami dan diakses. Informasi yang ditampilkan dapat dimanfaatkan sebagai sarana pemantauan dan referensi dalam memahami dinamika kualitas udara di wilayah perkotaan.


Dashboard ini dirancang sebagai sistem informatif dan prediktif yang menyajikan pemantauan kualitas udara secara *real-time* melalui beberapa fitur utama sebagai berikut:

1. Sistem mengintegrasikan data dari sensor kualitas udara berbasis IoT yang ditempatkan di beberapa lokasi di Kota Surabaya dengan data cuaca dan lingkungan dari Badan Meteorologi, Klimatologi, dan Geofisika (BMKG). Proses integrasi dilakukan secara *real-time* untuk menghasilkan data yang mutakhir dan terpusat.
2. Dashboard menyajikan visualisasi parameter kualitas udara, seperti PM2.5, PM10, NO2, CO dan O3, dalam bentuk grafik dan peta interaktif. Visualisasi ini bertujuan untuk memudahkan pengguna dalam memantau kondisi kualitas udara serta memahami pola dan tren temporal yang terjadi.
3. Sistem dilengkapi dengan fitur prediksi parameter kualitas udara menggunakan pendekatan *machine learning* berbasis algoritma XGBoost sebagai model utama. Model utama ini memanfaatkan fitur data historis (*lag features*), statistik bergerak (*rolling statistics*), serta variabel meteorologi lokal untuk menghasilkan estimasi konsentrasi polutan yang akurat pada horizon waktu 60 menit ke depan. Sebagai pembandingan, model regresi berbasis *tree* lainnya yaitu LightGBM serta metode statistik Prophet digunakan untuk mengevaluasi kinerja, kestabilan, dan konsistensi hasil prediksi jangka pendek yang ditampilkan pada sistem dashboard.

Dengan menggabungkan fitur-fitur tersebut, *dashboard* ini menjadi solusi teknologi yang dapat membantu pemerintah daerah dan masyarakat umum dalam memantau, mengantisipasi, dan mengambil keputusan berbasis data terkait kualitas udara

3.2 Perancangan Sistem


Arsitektur sistem pemantauan dan prediksi kualitas udara pada Gambar 3.1 dirancang dengan pendekatan modular yang terdiri atas empat proses utama, yaitu proses pengambilan data (*data acquisition*), penyimpanan backend, pengolahan dan prediksi data, serta visualisasi informasi. Setiap proses memiliki peran yang saling terintegrasi untuk memastikan aliran data berjalan secara efisien dari tahap pengukuran hingga penyajian informasi kepada pengguna.



Gambar 3.1 Desain Sistem

3.2.1 Perangkat Keras dan Sumber Data

Perancangan perangkat keras mencakup penyusunan dan perakitan sensor kualitas udara seperti PM2.5, PM10, NO₂, SO₂, dan O₃, yang dihubungkan dengan mikrokontroler ESP32. Data dari sensor akan dikirim melalui jaringan Wi-Fi menggunakan protokol MQTT ke server cloud. Prototipe perangkat keras dirancang untuk tahan terhadap kondisi lingkungan luar ruang, serta mudah dipasang di berbagai titik strategis di Kota Surabaya. Blok diagram sistem dapat dilihat pada gambar teknis (lihat Gambar 3.2).



Gambar 3.2 Blok Diagram Sistem

3.2.2 Proses Pengambilan Data (Data Acquisition)

Proses pengambilan data dilakukan menggunakan sensor kualitas udara berbasis IoT yang berfungsi mengukur parameter polutan dan kondisi lingkungan secara periodik. Data hasil pengukuran dikirimkan ke sistem melalui protokol HTTP dalam format JSON dan diterima oleh *Data Acquisition API*. API ini bertindak sebagai gerbang awal yang menangani penerimaan data sensor sebelum diteruskan ke sistem penyimpanan backend.

3.2.3 Proses Penyimpanan Backend (Supabase Backend)

Data sensor yang diterima selanjutnya dikirimkan ke backend Supabase melalui *Supabase REST API*. Backend ini menggunakan basis data PostgreSQL sebagai media penyimpanan terpusat. Data mentah hasil pengukuran disimpan pada tabel *sensor_data* sebagai data historis yang dapat digunakan untuk analisis lebih lanjut. Selain itu, hasil peramalan polutan udara disimpan pada tabel *forecast*, sehingga data aktual dan data peramalan dapat dikelola secara terpisah namun tetap terintegrasi.

3.2.4 Proses Pengolahan dan Peramalan Data (Data Processing & Forecasting)

Pada tahap Pengolahan dan Peramalan data, sistem menjalankan data *processing pipeline* berbasis Python yang secara periodik mengambil data sensor dari Supabase. Proses pengolahan meliputi pembersihan data, transformasi, serta pembentukan fitur yang dibutuhkan untuk pemodelan. Data yang telah diproses kemudian digunakan oleh modul peramalan berbasis model XGBoost untuk menghasilkan estimasi nilai polutan udara pada periode waktu

tertentu. Hasil peramalan yang dihasilkan selanjutnya disimpan kembali ke basis data Supabase pada tabel forecast.

3.2.5 Tahapan Pembuatan Model

Pembuatan model *machine learning* untuk pemantauan dan prediksi kualitas udara dilakukan melalui tahapan yang sistematis dan terstruktur guna menghasilkan model yang akurat, stabil, dan dapat diandalkan. Tahapan ini mencakup identifikasi fitur dan target, pembersihan serta transformasi data, pembagian data pelatihan dan pengujian, pelatihan model, hingga evaluasi kinerja model. Model yang digunakan dalam penelitian ini meliputi:

- XGBoost untuk keperluan peramalan konsentrasi polutan PM2.5, PM10, dan CO secara terpisah dengan horizon waktu 60 menit ke depan
- *Random Forest* sebagai model lapisan ketahanan (*robustness layer*) yang bertujuan meredam efek gangguan (*noise*)
- LightGBM dan Prophet sebagai model pembanding untuk evaluasi performa

3.2.5.1 Identifikasi Fitur dan Target

Tahap awal dalam pembuatan model adalah menentukan variabel fitur dan variabel target yang relevan. Untuk model klasifikasi kualitas udara, fitur yang digunakan meliputi konsentrasi polutan seperti PM2.5, PM10, CO, NO₂, dan O₃. Target dari model klasifikasi adalah kategori kualitas udara berdasarkan standar Indeks Standar Pencemar Udara (ISPU), yaitu *Baik*, *Sedang*, *Tidak Sehat*, *Sangat Tidak Sehat*, dan *Berbahaya*.

Untuk model prediksi, target dari model prediksi adalah nilai dari tiga parameter polutan utama, yaitu PM2.5, PM10, dan CO secara terpisah dengan horizon waktu 60 menit ke depan. Fitur prediksi mencakup nilai historis (lag features), serta fitur berbasis waktu seperti jam, hari, dan indikator tren. Penentuan fitur dan target yang tepat menjadi faktor penting dalam meningkatkan performa model prediksi.

Tabel 3.1 Fitur dan Target untuk Model

No	Nama Fitur	Tipe	Deskripsi
1	PM2.5	Numerik	Konsentrasi partikel halus udara
2	PM10	Numerik	Konsentrasi partikel kasar udara
3	NO ₂	Numerik	Konsentrasi nitrogen dioksida udara
4	CO	Numerik	Konsentrasi karbon monoksida udara
5	O ₃	Numerik	Konsentrasi ozon permukaan udara
6	Suhu	Numerik	Suhu udara lingkungan
7	Kelembapan	Numerik	Persentase kelembapan udara
8	Waktu (menit)	Kategorikal	Waktu pengambilan data
9	Target ISPU	Kategorikal	Kategori kualitas udara

3.2.5.2 Pembersihan dan Transformasi Data

Data yang diperoleh dari sensor IoT berpotensi mengandung *noise*, nilai kosong (*missing values*), dan pencilan. Oleh karena itu, dilakukan tahap pembersihan data untuk memastikan kualitas *dataset*. Nilai kosong ditangani menggunakan metode interpolasi atau pengisian berbasis nilai statistik, sedangkan pencilan diidentifikasi dan ditangani menggunakan metode Interquartile Range (IQR).

Pada tahap transformasi, dilakukan pembentukan fitur waktu dan lag data untuk mendukung pemodelan deret waktu. Normalisasi data tidak diwajibkan untuk model berbasis pohon keputusan seperti XGBoost, dan LightGBM, karena model tersebut tidak sensitif terhadap skala fitur. Namun, normalisasi tetap dapat diterapkan untuk keperluan eksplorasi dan konsistensi data.

3.2.5.3 Pembagian Data: Pelatihan dan Pengujian

Dataset dibagi menjadi data pelatihan dan data pengujian dengan rasio 80% untuk pelatihan dan 20% untuk pengujian. Untuk model klasifikasi Random Forest, pembagian data dapat dilakukan secara acak (*shuffle*), karena setiap observasi dianggap independen dan tidak ada ketergantungan temporal yang signifikan antar kelas.

Untuk model prediksi deret waktu seperti XGBoost dan Prophet, pembagian data dilakukan berdasarkan urutan waktu tanpa pengacakan untuk menjaga struktur temporal. Strategi ini penting karena:

1. Menghindari kebocoran informasi dari masa depan ke masa lalu
2. Mensimulasikan kondisi nyata di mana model harus memprediksi data yang belum terlihat
3. Memastikan validitas evaluasi yang representatif

Selain itu, validasi berbasis time series cross-validation atau rolling window digunakan untuk mengevaluasi kemampuan model dalam melakukan generalisasi pada data masa depan. Rolling window validation sangat penting untuk data berkualitas udara yang bersifat dinamis dan berubah sepanjang waktu.

3.2.5.4 Pelatihan Model

Pelatihan model dilakukan menggunakan beberapa algoritma yang telah dievaluasi melalui eksperimen komprehensif sebagai berikut:

Untuk Peramalan (Forecasting):

- XGBoost (*eXtreme Gradient Boosting*): Model utama untuk peramalan kualitas udara. XGBoost dipilih karena kemampuannya menangani hubungan non-linear yang kompleks antara variabel polutan dan faktor meteorologi, serta adanya regularisasi eksplisit (L1 dan L2) untuk mencegah *overfitting*. Secara konseptual, model ini ditempatkan sebagai pilar utama karena arsitektur *gradient boosting* sekuensialnya dirancang untuk meminimalkan kesalahan secara bertahap pada setiap iterasi pohon keputusan, sehingga mampu menghasilkan estimasi peramalan yang paling presisi dan stabil dalam menangkap variabilitas data di lapangan.

- **LightGBM** (*Light Gradient Boosting Machine*): Model pembanding yang dikenal karena kecepatan komputasi yang tinggi melalui strategi pertumbuhan pohon secara vertikal (*leaf-wise growth strategy*). Meskipun sangat efisien dalam memangkas waktu pelatihan (*training time*), secara konseptual model ini digunakan untuk mengevaluasi apakah pendekatan berbasis histogram mampu menghasilkan akumulasi kesalahan yang setara atau lebih baik daripada model utama ketika dihadapkan pada karakteristik data polutan yang memiliki fluktuasi jangka pendek yang sangat tajam.
- **Prophet** – Model pembanding berbasis statistik yang dirancang menggunakan pendekatan *decomposable additive model* untuk memisahkan komponen tren makro dan pola musiman harian (*diurnal*) secara otomatis. Peran Prophet dalam penelitian ini adalah sebagai *baseline* pembanding konvensional. Secara konseptual, model statistik ini digunakan untuk menguji sejauh mana model berbasis *machine learning* mampu memberikan peningkatan performa penekanan kesalahan yang signifikan, mengingat landasan matematis Prophet yang kaku pada deret Fourier umumnya memiliki keterbatasan dalam mengadaptasi riak fluktuasi acak berfrekuensi tinggi (per menit).

3.2.5.5 Penggunaan Model Stabilisasi Keputusan dan Peramalan

Transformasi ISPU dan *Random Forest* sebagai Lapisan Ketahanan (*Robustness Layer*)

Dalam sistem ini, penentuan label kualitas udara (Baik, Sedang, Tidak Sehat, Sangat Tidak Sehat, dan Berbahaya) dilakukan secara deterministik menggunakan transformasi matematis berbasis *breakpoint* ISPU sesuai standar regulasi yang berlaku. Algoritma *Random Forest*, yang merupakan metode *ensemble* berbasis pohon keputusan (*decision tree*), tidak difungsikan untuk menggantikan aturan pasti tersebut, melainkan diimplementasikan sebagai lapisan ketahanan (*robustness layer*).

Tugas utama *Random Forest* dalam ekosistem ini adalah melakukan stabilisasi keputusan (*decision smoothing*) untuk meredam efek anomali atau fluktuasi pembacaan sensor IoT, terutama ketika nilai polutan berada tepat di batas ambang (*boundary*) transisi antar kategori.

Keunggulan penggunaan *Random Forest* sebagai *robustness layer* dalam penelitian ini meliputi:

- Kemampuannya untuk mempertahankan akurasi keputusan (*graceful degradation*) meskipun data input dari sensor mengalami *noise* atau kerusakan kalibrasi parsial (*drift*).
- Ketahanan terhadap *overfitting* saat memetakan interaksi multivariat dari 5 parameter polutan mentah (PM2.5, PM10, CO, NO₂, dan O₃).
- Fitur *feature importance* yang memungkinkan analisis kontribusi masing-masing polutan terhadap pergeseran kualitas udara di lapangan.

XGBoost sebagai Model Peramalan Utama

XGBoost digunakan sebagai model utama untuk memprediksi konsentrasi polutan pada horizon waktu 60 menit ke depan. Keunggulan XGBoost dalam penelitian ini antara lain kemampuan menangani data dengan kompleksitas tinggi, regularisasi eksplisit (L1 dan L2) untuk mengurangi overfitting, keunggulan dalam menangani hubungan non-linear dan interaksi kompleks antar fitur, serta performa yang sangat tinggi pada berbagai studi prediksi kualitas udara.

3.2.5.6 Penggunaan Model Peramalan

Untuk melakukan peramalan kadar polutan di masa depan, penelitian ini menggunakan pendekatan *machine learning* berbasis supervised learning dengan XGBoost sebagai model prediksi utama. Selain itu, LightGBM dan Prophet digunakan sebagai model pembandingan untuk mengevaluasi kestabilan dan konsistensi hasil prediksi.

XGBoost sebagai Model Prediksi Utama

XGBoost diimplementasikan sebagai model prediksi numerik (regression) untuk meramalkan nilai polutan pada horizon waktu 60 menit ke depan. Pendekatan ini dilakukan dengan mengonversi permasalahan deret waktu menjadi masalah regresi terawasi (time series regression).

Dalam implementasinya, prediksi dilakukan dengan memanfaatkan:

- Fitur lag waktu, seperti nilai polutan pada waktu ke-($t-1$), ($t-2$), hingga ($t-60$)

- Fitur temporal, seperti jam, hari, dan indikator periode waktu tertentu
- Fitur meteorologis, seperti suhu dan kelembapan udara
- Fitur rolling statistics (rata-rata dan standar deviasi bergerak)

Keunggulan XGBoost sebagai model prediksi dalam penelitian ini antara lain kemampuan menangkap hubungan non-linear dan interaksi kompleks antar variabel polutan dan faktor lingkungan, regularisasi eksplisit untuk mencegah overfitting, pemanfaatan second-order gradient untuk konvergensi yang lebih cepat, serta skalabilitas yang memungkinkan pembaruan model secara bertahap.

LightGBM sebagai Model Pembandingan

LightGBM digunakan sebagai model pembandingan yang mengimplementasikan arsitektur gradient boosting dengan pendekatan leaf-wise tree growth, berbeda dengan XGBoost yang menggunakan *level-wise*. Keunggulan LightGBM meliputi kecepatan pelatihan yang lebih tinggi dan konsumsi memori yang lebih rendah, sehingga cocok untuk *dataset* dengan jumlah baris yang besar. *Feature engineering* yang digunakan identik dengan XGBoost untuk memastikan perbandingan yang adil. LightGBM menjadi tolok ukur untuk mengevaluasi apakah kompleksitas XGBoost memberikan peningkatan akurasi yang signifikan.

Prophet sebagai Model Pembandingan

Prophet digunakan sebagai model pembandingan untuk memberikan perspektif peramalan berbasis pendekatan statistik-additive. Model ini memisahkan deret waktu menjadi beberapa komponen utama, yaitu tren, musiman, dan *noise*.

Peran Prophet dalam penelitian ini adalah:

- Menjadi baseline model peramalan deret waktu
- Membandingkan akurasi dan stabilitas peramalan terhadap LightGBM
- Mengevaluasi kemampuan model dalam menangkap pola musiman harian dan mingguan

Meskipun Prophet relatif lebih sederhana dibandingkan LightGBM, penggunaannya penting untuk menilai apakah kompleksitas model *machine learning* memberikan peningkatan performa yang signifikan dibandingkan metode peramalan konvensional.

3.2.5.7 Evaluasi Kinerja Model

Mean Absolute Error (MAE) mengukur rata-rata selisih absolut antara nilai hasil peramalan dan nilai aktual. Metrik ini memberikan gambaran langsung mengenai besar kesalahan peramalan tanpa memperhatikan arah kesalahan. MAE bersifat mudah diinterpretasikan karena berada pada satuan yang sama dengan variabel yang diprediksi, sehingga cocok untuk mengevaluasi akurasi peramalan kadar polutan dan ISPU.

Root Mean Squared Error (RMSE) mengukur akar dari rata-rata kuadrat selisih antara nilai peramalan dan nilai aktual. Metrik ini memberikan penalti yang lebih besar terhadap kesalahan peramalan yang ekstrem (*outlier*), sehingga sensitif terhadap deviasi besar. RMSE digunakan untuk menilai stabilitas dan ketelitian model dalam meramalkan perubahan kualitas udara yang signifikan.

Mean Absolute Percentage Error (MAPE) mengukur tingkat kesalahan peramalan dalam bentuk persentase terhadap nilai aktual. Metrik ini berguna untuk menilai tingkat kesalahan relatif model dan memudahkan perbandingan performa antar model dalam konteks yang lebih intuitif. Namun, penggunaan MAPE diperhatikan secara hati-hati pada nilai aktual yang sangat kecil untuk menghindari distorsi nilai kesalahan.

Hasil evaluasi berdasarkan ketiga metrik tersebut (MAE, RMSE, dan MAPE) digunakan untuk membandingkan kinerja model XGBoost dan Prophet secara objektif. Model dengan nilai kesalahan MAE, RMSE, dan MAPE yang lebih rendah akan dipilih sebagai model peramalan utama yang diintegrasikan ke dalam sistem operasional. Selain itu, hasil evaluasi ini juga menjadi dasar untuk menilai kelayakan model dalam mendukung penyajian informasi prediktif yang akurat dan andal pada dashboard pemantauan kualitas udara berbasis web.

Untuk Model Klasifikasi (Robustness Layer), metrik evaluasi yang digunakan meliputi Accuracy dan F1-Score Macro pada skenario data riil, serta pengujian ketahanan degradasi performa (Drift Test) menggunakan simulasi injeksi noise bertingkat (5% hingga 25%) untuk mengukur stabilitas model terhadap anomali sensor.

3.2.5.8 Horizon Peramalan 60 Menit

Sistem peramalan yang dikembangkan memiliki kemampuan untuk meramalkan konsentrasi polutan hingga 60 menit ke depan (1 jam). Hal ini berbeda dengan penelitian lain yang hanya meramalkan 1 menit ke depan, karena horizon peramalan yang lebih panjang memberikan manfaat yang lebih besar bagi pengguna dalam perencanaan aktivitas dan pengambilan keputusan terkait kesehatan.

Dashboard menampilkan 60 titik peramalan yang masing-masing mewakili peramalan 1 menit, 2 menit, hingga 60 menit ke depan. Setiap iterasi peramalan menggunakan nilai peramalan sebelumnya sebagai input untuk step berikutnya (recursive forecasting), memastikan kontinuitas data antar titik waktu yang berurutan.

3.2.6 Implementasi Backend dan Logika Pemrosesan Data

Implementasi backend pada sistem pemantauan kualitas udara ini dirancang untuk menangani data sensor berfrekuensi tinggi secara efisien, stabil, dan berkelanjutan. Data yang dikirimkan oleh perangkat IoT berupa parameter polutan udara dan kondisi meteorologis diterima melalui REST API Supabase dan disimpan terlebih dahulu ke dalam tabel data mentah `tb_konsentrasi_gas`. Penyimpanan data mentah ini bertujuan untuk menjaga integritas data asli hasil pengukuran sensor serta memungkinkan proses analisis lanjutan apabila diperlukan.

tb_konsentrasi_gas

tb_prediksi_kualitas_udara

tb_analog_out

air_quality_hourly_agg

Filter by id, created_at, pm25_ugm3... or ask AI

	id int8	created_at timestampz	pm25_ugm3 fl...	pm10_ugm3 fl...	co_ugm3 fl...
	123003	2026-06-16 06:22:34.348949+00	12.07	10.5	1199.01
	123002	2026-06-16 06:21:31.728974+00	11.54	9.8	1190.45
	123001	2026-06-16 06:17:26.565392+00	8.54	10.5	1241.41
	123000	2026-06-16 06:16:20.684575+00	12.42	8.41	1339.76
	122999	2026-06-16 06:15:29.666932+00	10.31	9.34	1250.4
	122998	2026-06-16 06:14:21.895697+00	9.95	9.34	1241.41
	122997	2026-06-16 06:13:16.992667+00	9.6	8.87	1251.91

Gambar 3.3 Struktur Tabel Data mentah

Seiring berjalannya waktu, tabel data mentah mengalami pertumbuhan data yang sangat cepat karena pengiriman data dilakukan secara periodik dalam interval waktu pendek. Apabila data mentah tersebut diakses secara langsung oleh aplikasi *dashboard* untuk keperluan visualisasi, maka akan muncul permasalahan performa *query* akibat volume data yang besar,


serta ketidakstabilan tampilan grafik karena perubahan data yang terlalu sering. Kondisi ini dapat mengurangi responsivitas sistem dan kenyamanan pengguna dalam memantau tren kualitas udara.

Untuk mengatasi permasalahan tersebut, *backend* sistem ini mengimplementasikan mekanisme pemrosesan data berbasis agregasi ter-materialisasi (*materialized aggregation*). Pendekatan ini dilakukan dengan membangun tabel agregasi terpisah di Supabase yang berfungsi menyimpan data hasil pengolahan dari tabel data mentah. Data pada tabel agregasi telah diringkas berdasarkan interval waktu tertentu, seperti per jam atau per hari, sehingga jumlah data yang diakses oleh dashboard menjadi lebih kecil dan lebih representatif terhadap pola kualitas udara yang ingin ditampilkan.

	time timesta...	pm25_ugm3 nu...	pm10_corrected_ugm3 numeric	no2_ugm3 nu...	co_ugm3 nu...
	2026-06-16 05:00:00+00	9.69172413793104	10.3524137931035	0	1292.48896551724
	2026-06-16 04:00:00+00	9.78559322033898	10.4235593220339	0	1240.14237288136
	2026-06-16 03:00:00+00	10.075593220339	10.7894915254237	0	1195.76440677966
	2026-06-16 02:00:00+00	10.9720338983051	12.0186440677966	0	1180.0686440678
	2026-06-16 01:00:00+00	11.3348214285714	12.4396428571429	0	1134.0325
	2026-06-16 00:00:00+00	12.0681355932203	13.4591525423729	0	1140.19084745763
	2026-06-15 23:00:00+00	13.6006779661017	14.9184745762712	0	1175.35491525424
	2026-06-15 22:00:00+00	13.0841818181818	14.8965454545455	0	1189.32090909091

Gambar 3.4 Struktur Tabel Data agregasi

Proses agregasi data dijalankan menggunakan Supabase Edge Functions yang berperan sebagai lapisan logika pemrosesan backend. Edge Function ini secara periodik mengambil data dari tabel *tb_konsentrasi_gas*, melakukan pengelompokan data berdasarkan rentang waktu yang telah ditentukan, kemudian menghitung nilai agregat seperti rata-rata konsentrasi polutan, nilai maksimum, dan minimum. Hasil pengolahan tersebut selanjutnya disimpan ke dalam tabel agregasi yang telah disediakan.




Gambar 3.5 Alur Agregasi Otomatis

Alur agregasi data dimulai dari pemicu terjadwal yang mengirimkan permintaan HTTP ke Edge Function Supabase. Edge Function memvalidasi permintaan, menginisialisasi koneksi menggunakan *service role key*, lalu memanggil fungsi RPC di *database* untuk melakukan agregasi data dari tabel mentah ke tabel agregasi. Setelah proses selesai, sistem mengevaluasi hasil eksekusi; jika berhasil, data agregasi disimpan dan siap digunakan untuk visualisasi, sedangkan jika gagal, kesalahan dicatat dan respons kesalahan dikembalikan.

3.2.6.1 Otomasi Pemrosesan Data Terjadwal

Untuk memastikan proses pemrosesan dan agregasi data berjalan secara konsisten tanpa interaksi pengguna, sistem *backend* menerapkan mekanisme eksekusi terjadwal. Proses ini dijalankan secara otomatis pada interval waktu tertentu untuk mengeksekusi fungsi pemrosesan data di sisi server. Pendekatan ini memungkinkan data hasil agregasi selalu diperbarui secara berkala, sekaligus menjaga stabilitas performa sistem dengan memisahkan proses komputasi dari permintaan langsung *dashboard*. Pada tahap implementasi, mekanisme eksekusi terjadwal tersebut direalisasikan menggunakan *cron job* yang dijalankan pada lingkungan server Supabase. Cron job digunakan untuk memicu Edge Function pada interval waktu tertentu sesuai kebutuhan sistem.



Gambar 3.6 Riwayat eksekusi agregasi Cron Job

3.2.7 Proses Pembuatan Dashboard

Tahap pembuatan dashboard berbasis web difokuskan pada perancangan antarmuka yang berfungsi sebagai pusat visualisasi dan penyampaian informasi kualitas udara kepada pengguna. Dashboard ini dirancang untuk mengintegrasikan data sensor kualitas udara yang

diperoleh secara *real-time* dengan hasil analisis dan prediksi yang dihasilkan oleh sistem pemodelan. Seluruh data tersebut diakses melalui Supabase menggunakan REST API, sehingga proses pengambilan data dapat dilakukan secara efisien, terstruktur, dan mudah dikembangkan di masa mendatang.

Dalam implementasinya, dashboard secara periodik mengambil data konsentrasi polutan seperti PM2.5, PM10, CO, NO₂, dan O₃ serta parameter pendukung lainnya yang tersimpan pada basis data Supabase. Data ini kemudian diproses pada sisi frontend untuk ditampilkan dalam bentuk grafik deret waktu (*time-series*) yang memungkinkan pengguna mengamati pola perubahan kualitas udara dari waktu ke waktu. Penggunaan visualisasi berbasis grafik dipilih karena mampu menyajikan informasi numerik yang kompleks secara lebih intuitif dan mudah dipahami oleh pengguna non-teknis. Selain menampilkan data historis *dan real-time*, dashboard juga menyajikan hasil prediksi kualitas udara yang dihasilkan oleh model *machine learning*. Informasi prediktif ini ditampilkan berdampingan dengan data aktual, sehingga pengguna dapat membandingkan kondisi saat ini dengan perkiraan kondisi udara pada periode waktu mendatang.

3.2.8 Perencanaan Pengambilan Sampel dan Analisis Spasial Kualitas Udara

Tahapan perencanaan pengambilan sampel dan analisis spasial kualitas udara dilakukan untuk mengidentifikasi variasi kondisi kualitas udara pada titik pemantauan dengan karakteristik aktivitas yang berbeda di Kota Surabaya. Analisis spasial digunakan untuk memahami distribusi kualitas udara berdasarkan karakteristik lingkungan dan sumber emisi dominan pada masing-masing lokasi pengamatan.

3.2.8.1 Pengambilan Sampel Data Spasial

Pengambilan sampel data spasial dilakukan pada tiga titik pengamatan yang mewakili karakteristik lingkungan yang berbeda di Kota Surabaya, yaitu titik pemantauan Ngagel, titik pemantauan Rungkut, dan titik pemantauan Margomulyo. Pemilihan lokasi dilakukan secara *purposive sampling* dengan mempertimbangkan karakteristik aktivitas dominan pada masing-masing titik pemantauan. Penempatan alat pemantau dilakukan secara spesifik pada titik koordinat geografis yang telah ditetapkan agar representasi data yang diambil tetap presisi dan dapat dipertanggungjawabkan secara spasial. Rincian lokasi pengambilan sampel kualitas udara ditunjukkan pada Tabel 3.2.

Tabel 3.2 Titik Koordinat Lokasi Pengambilan Sampel Spasial

Titik Pemantauan	Representasi Aktivitas	Lokasi Jalan / Area	Titik Koordinat
Ngagel	Lalu Lintas Perkotaan & Permukiman	Jl. Raya Ngagel, Wonokromo	-7.290305, 112.760404
Rungkut	Industri Manufaktur & Pendidikan	Jalan Rungkut Madya	-7.332245, 112.789994
Margomulyo	Industri Logistik & Lalu Lintas Berat	Simpang Jl. Margomulyo, Tandes	-7.258845, 112.682067

Titik pemantauan Rungkut dipilih sebagai representasi titik pemantauan industri manufaktur yang dipengaruhi oleh aktivitas titik pemantauan industri dan distribusi barang. Sementara itu, titik pemantauan Margomulyo dipilih sebagai representasi titik pemantauan industri-logistik dan pergudangan yang didominasi oleh aktivitas kendaraan berat dan transportasi logistik. Pada setiap lokasi pengamatan, alat pemantauan kualitas udara ditempatkan pada titik yang dapat merepresentasikan kondisi lingkungan sekitar dan memiliki akses pengamatan yang memadai. Sebelum pengambilan data dilakukan, alat dipastikan berada dalam kondisi stabil dan telah melalui proses *warming-up* untuk mengurangi kesalahan pengukuran. Data kualitas udara yang dikumpulkan meliputi konsentrasi PM_{2.5}, PM₁₀, karbon monoksida (CO), suhu udara, dan kelembapan udara. Pengukuran dilakukan selama periode waktu tertentu pada masing-masing titik pengamatan, kemudian setiap data dikaitkan dengan koordinat geografis lokasi pengambilan sampel untuk mendukung analisis spasial dan visualisasi distribusi kualitas udara.

Hasil pengukuran dari ketiga titik tersebut digunakan untuk membandingkan kondisi kualitas udara berdasarkan karakteristik lingkungan yang berbeda, sehingga dapat memberikan gambaran mengenai pengaruh aktivitas perkotaan, industri manufaktur, dan logistik terhadap kualitas udara di Kota Surabaya.

3.2.8.2 Analisis Data Spasial

Analisis data spasial dilakukan sebagai studi kasus tambahan dengan membandingkan hasil pengukuran kualitas udara pada tiga lokasi yang mewakili

karakteristik lingkungan berbeda, yaitu titik pemantauan Ngagel, Rungkut, dan Margomulyo. Parameter utama yang dievaluasi meliputi konsentrasi PM2.5, PM10, dan karbon monoksida COO. Untuk membuktikan secara statistik apakah terdapat perbedaan tingkat paparan emisi yang signifikan akibat karakteristik aktivitas di masing-masing wilayah, analisis tidak hanya dilakukan secara deskriptif, tetapi dilanjutkan dengan uji inferensial komparatif menggunakan metode *One-Way ANOVA*.

Skenario analisis spasial ini diawali dengan pengujian asumsi parametrik melalui uji normalitas *Shapiro-Wilk* dan uji homogenitas varians *Levene*. Apabila hasil komputasi ANOVA menolak hipotesis nol H_0 , tahapan analisis akan dilanjutkan dengan uji komparasi ganda *Post-hoc Tukey HSD*. Pengujian lanjutan ini diterapkan untuk memetakan secara spesifik pasangan titik lokasi mana saja yang memiliki perbedaan tingkat pencemaran paling tajam di lapangan.

3.2.8.3 Interpretasi Hasil Analisis

Interpretasi hasil analisis dilakukan dengan mengaitkan signifikansi perbedaan nilai parameter kualitas udara yang diperoleh melalui uji statistik pada setiap lokasi pengamatan dengan karakteristik lingkungan dan aktivitas di sekitarnya. Hasil komparasi pada titik pemantauan Ngagel, Rungkut, dan Margomulyo akan dianalisis lebih dalam untuk memahami pengaruh aktivitas lalu lintas perkotaan, industri manufaktur, dan titik pemantauan logistik terhadap tingkat paparan polusi udara. Interpretasi ini digunakan untuk menjelaskan pola variasi emisi yang teramati, sekaligus mengevaluasi kemampuan model analitik pada sistem pemantauan berbasis IoT dalam merespons dan merepresentasikan kondisi lingkungan pada lokasi pengamatan yang berbeda.

3.3 Desain Mockup

Bab ini membahas perancangan antarmuka pengguna (*user interface*) untuk sistem pemantauan kualitas udara berbasis web. Desain mockup dashboard dirancang dengan pendekatan user-centered design untuk memberikan visualisasi data yang mudah dipahami oleh berbagai kalangan pengguna. Dashboard terdiri dari beberapa halaman utama yang dapat diakses melalui navigasi tab, yaitu Overview untuk ringkasan kualitas udara *real-time*, dan Prediksi Kualitas udara berbasis *machine learning*.


3.3.1 Dashboard Overview

Gambar 3.7 menampilkan *mock-up* halaman utama (*Overview*) dari *dashboard* pemantauan kualitas udara. Halaman ini dirancang sebagai pusat informasi utama yang memberikan ringkasan komprehensif mengenai status mutu udara saat ini. Pada bagian pojok kanan atas, terdapat indikator tanggal dan waktu (*timestamp*) yang terus diperbarui untuk menegaskan bahwa sistem menyajikan data yang bersifat *real-time*.

Antarmuka halaman ini terbagi menjadi beberapa panel informasi utama sebagai berikut:

- **Panel Klasifikasi Kualitas Udara:** Panel ini merupakan visualisasi langsung dari hasil penentuan status mutu udara. Di sebelah kiri, terdapat *gauge chart* berbentuk lingkaran yang menampilkan kategori ISPU secara visual. *Gauge* ini terhubung dengan perhitungan deterministik ISPU *breakpoint* yang telah diperkuat oleh model *Random Forest* sebagai lapisan ketahanan (*robustness layer*) untuk menstabilkan pergerakan jarum indikator. Di sebelah kanan *gauge*, sistem menyajikan narasi penjelasan terkait dampak kesehatan dari kondisi udara tersebut secara deskriptif, sehingga mudah dipahami oleh masyarakat awam. Panel ini juga dilengkapi dengan legenda rentang nilai dan warna ISPU (mulai dari rentang 0-50 untuk "Baik" hingga 301-500 untuk "Berbahaya").
- **Kartu Metrik Polutan (*Pollutant Metric Cards*):** Tepat di bawah panel klasifikasi, terdapat lima kartu metrik yang disusun secara sejajar (horizontal). Masing-masing kartu merepresentasikan parameter polutan yang dipantau, yaitu PM2.5, PM10, NO₂, CO, dan O₃. Kartu-kartu ini menampilkan angka spesifik konsentrasi dalam format ISPU beserta label status keselamatannya (contoh: "Aman"). Warna latar belakang kartu akan berubah secara dinamis mengikuti tingkat keparahan polutan berdasarkan standar indeks warna ISPU.
- **Panel Ringkasan PM2.5:** Terletak di bagian kiri bawah, panel ini berfungsi untuk memberikan wawasan historis jangka pendek mengenai polutan paling kritis (PM2.5). Panel ini menampilkan rata-rata ISPU PM2.5 selama 7 hari terakhir dalam bentuk *slider bar* berwarna, lengkap dengan nilai historis terendah, tertinggi, nilai mendekati puncak (*hampir tertinggi*), serta indikator persentase tren pergerakan polutan (naik atau turun).
- **Panel Kondisi Ruang / Lingkungan:** Berada di tengah bagian bawah, panel ini menyajikan data meteorologi mikro atau parameter lingkungan lokal tempat sensor utama dipasang. Informasi yang disajikan mencakup pembacaan Suhu (contoh: 34.5°C)

dan Kelembapan (contoh: 63.3%), yang berfungsi sebagai variabel pendukung untuk memahami faktor fisik yang memengaruhi akumulasi polutan di udara sekitar sensor.



Gambar 3.7 Mock-up Metrics Card

3.3.2 Data Cuaca BMKG dan Tren Polutan


Gambar 3.8 menampilkan *mock-up* antarmuka panel "Data BMKG" yang berfungsi mengintegrasikan parameter meteorologi eksternal ke dalam sistem pemantauan kualitas udara. Panel ini dirancang dengan tata letak (*layout*) berbasis kartu (*card*) yang bersih dan modern, serta dilengkapi dengan tombol interaktif Refresh di sudut kanan atas yang memungkinkan pengguna untuk memuat ulang data cuaca secara manual kapan saja.

Informasi meteorologi disajikan secara intuitif yang diawali dengan indikator kondisi cuaca umum (seperti "Cerah Berawan"), lengkap dengan ikon visual yang merepresentasikan keadaan langit aktual. Tepat di bawah indikator utama tersebut, terdapat empat metrik parameter cuaca spesifik yang disusun dalam format *grid*, yaitu:

- Suhu: Menampilkan temperatur lingkungan aktual (contoh: 29°C) dengan ikon termometer.
- Kelembapan: Menampilkan persentase kelembapan udara relatif (contoh: 67%) dengan ikon tetesan air.
- Angin: Menampilkan kecepatan pergerakan angin (contoh: 12.7 km/h) dengan ikon hembusan angin.
- Arah: Menunjukkan indikator arah mata angin dominan (contoh: W yang merepresentasikan *West* atau Barat) dengan ikon kompas.

Kehadiran informasi cuaca ini sangat esensial di dalam *dashboard*, mengingat parameter meteorologi seperti arah angin, kecepatan angin, suhu, dan kelembapan merupakan

variabel prediktor yang memiliki korelasi dan pengaruh langsung terhadap tingkat dispersi maupun akumulasi polutan udara di suatu titik pemantauan.



Gambar 3.8 Mock-up Integrasi Data BMKG

3.3.3 Prediksi Kualitas Udara dengan Model *Machine Learning*

Gambar 3.9 menampilkan *mock-up* halaman "Statistik & Analisis Data" yang secara khusus menyajikan hasil peramalan kualitas udara menggunakan model *machine learning*. Antarmuka pada halaman ini dirancang untuk memberikan wawasan mendalam terkait proyeksi kondisi udara di masa depan dan terbagi menjadi dua bagian visual utama:

- Panel Prediksi 1 Jam (ISPU): Terletak di bagian atas, panel ini memvisualisasikan proyeksi nilai ISPU untuk tiga parameter polutan utama (PM2.5, PM10, dan CO) selama 60 menit (1 jam) ke depan menggunakan grafik area (*area chart*) berlapis. Grafik ini menggunakan representasi warna yang berbeda untuk setiap polutan (ungu untuk PM2.5, hijau untuk PM10, dan oranye untuk CO) agar pengguna dapat melihat fluktuasi ketiganya secara simultan. Pada bagian kiri atas, terdapat kartu indikator yang menampilkan status kualitas udara dominan (contoh: "Baik") beserta rincian nilai ISPU tiap polutan. Panel ini juga dilengkapi tombol *toggle* di sudut kanan atas yang memungkinkan pengguna untuk beralih antara tampilan "Grafik" visual atau "Tabel" data numerik.
- Panel *Forecasting & Analitik*: Berada di bagian bawah, panel ini secara spesifik menampilkan hasil peramalan nilai konsentrasi polutan mentah (dalam satuan $\mu\text{g}/\text{m}^3$) menggunakan algoritma peramalan XGBoost. Visualisasi grafik deret waktu dirancang secara intuitif dengan membedakan bentuk garis: sisi kiri dengan area biru dan garis

tegak (*solid line*) merepresentasikan data aktual saat ini, sedangkan sisi kanan dengan area oranye dan garis putus-putus (*dashed line*) merepresentasikan tren hasil peramalan ke masa depan.



Gambar 3.9 Mock-up Hasil Prediksi

BAB 4

HASIL PENELITIAN

Pada bab ini membahas tentang implementasi teknis pengembangan dashboard *real-time* untuk monitoring dan prediksi kualitas udara di Kota Surabaya. Sistem dirancang menggunakan arsitektur backend terintegrasi yang mampu menangani data sensor berfrekuensi tinggi melalui mekanisme penyimpanan, agregasi, dan otomatisasi pemrosesan data guna menjaga kinerja query dan stabilitas visualisasi. Data kualitas udara yang diterima secara periodik diproses lebih lanjut untuk menghasilkan informasi teragregasi yang siap ditampilkan pada dashboard. Selain itu, sistem mengimplementasikan model prediksi kualitas udara berbasis *machine learning* yang telah melalui tahap pelatihan dan evaluasi, sehingga mampu menghasilkan peramalan yang akurat berdasarkan data historis.

4.1 Parameter Eksperimen

Parameter Model XGBoost

Pada proyek akhir ini, model XGBoost digunakan sebagai model utama untuk prediksi kualitas udara. Parameter utama yang digunakan dapat dilihat pada Tabel 4.1.

Tabel 4.1 Hyperparameter Model XGBoost

No	Parameter	Nilai	Deskripsi
1	n_estimators	300	Jumlah pohon boosting yang dibangun
2	max_depth	6	Kedalaman maksimum setiap pohon
3	learning_rate	0.05	Laju pembelajaran (step size)
4	reg_alpha (L1)	0.1	Regularisasi L1 untuk sparsity
5	reg_lambda (L2)	1.0	Regularisasi L2 untuk stabilitas
6	objective	reg:squarederror	Fungsi objektif regresi
7	random_state	42	Seed untuk reproduktibilitas

Parameter Model LightGBM

Pada proyek akhir ini, model Light Gradient Boosting Machine (LightGBM) digunakan sebagai model pembandingan untuk peramalan kualitas udara.. Parameter utama yang digunakan dapat dilihat pada Tabel 4.2

Tabel 4.2 Hyperparameter Model LightGBM

No	Parameter	Nilai Aktual	Deskripsi
1	n_estimators	100	Jumlah pohon keputusan boosting yang dibangun pada model.
2	max_depth	6	Batasan kedalaman maksimum pembelahan pada struktur vertikal daun.
3	learning_rate	0.1	Laju pembelajaran model untuk penyesuaian bobot residual komputasi.
4	random_state	42	Bilangan acak konstan untuk menjamin reproduksibilitas hasil pemodelan.

Parameter Model Prophet

Model Prophet digunakan sebagai model pembandingan untuk peramalan deret waktu karena kemampuannya dalam menangani tren dan pola musiman secara otomatis. Parameter utama yang digunakan dapat dilihat pada Tabel 4.3.

Tabel 4.3 Parameter Model Prophet

No	Parameter Target	Mode Fungsi	Changepoint Prior Scale (cps)	Daily Seasonality
1	PM2.5	Additive	0.01	TRUE
2	PM10	Additive	0.01	TRUE
3	CO	Additive	0.05	TRUE

4.2 Karakteristik Data

Data yang digunakan dalam penelitian ini merupakan data kualitas udara yang diperoleh dari sensor berbasis Internet of Things (IoT) yang ditempatkan di wilayah Kota Surabaya. Data dikumpulkan secara kontinu dengan frekuensi tinggi (per menit) dan dikirimkan ke sistem backend melalui REST API untuk kemudian disimpan dalam basis data Supabase (PostgreSQL). *Dataset* ini mencakup parameter polutan utama dan variabel meteorologis yang digunakan sebagai dasar analisis monitoring serta pemodelan prediksi kualitas udara yang ditunjukkan pada Tabel 4.4.

Tabel 4.4 Karakteristik Dataset

No	Atribut	Deskripsi	Tipe Data
1	created_at	Waktu pencatatan data sensor, direkam secara <i>real-time</i> dengan interval per menit.	datetime
2	pm25_ugm3	Konsentrasi partikel PM2.5 dalam satuan mikrogram per meter kubik ($\mu\text{g}/\text{m}^3$).	numeric
3	pm10_ugm3	Konsentrasi partikel PM10 dalam satuan mikrogram per meter kubik ($\mu\text{g}/\text{m}^3$).	numeric
4	co_ugm3	Konsentrasi karbon monoksida (CO) dalam satuan mikrogram per meter kubik ($\mu\text{g}/\text{m}^3$).	numeric
5	no2_ugm3	Konsentrasi nitrogen dioksida (NO_2) dalam satuan mikrogram per meter kubik ($\mu\text{g}/\text{m}^3$).	numeric
6	o3_ugm3	Konsentrasi ozon (O_3) dalam satuan mikrogram per meter kubik ($\mu\text{g}/\text{m}^3$).	numeric
7	temperature	Suhu udara lingkungan yang diukur oleh sensor dalam derajat Celcius ($^{\circ}\text{C}$).	numeric
8	humidity	Kelembapan relatif udara dalam persentase (%).	numeric

4.3 Lokasi Uji Coba

Permohonan izin diajukan kepada dosen pembimbing untuk melakukan penempatan dan pengujian perangkat sensor kualitas udara di lingkungan kampus. Perangkat sensor ditempatkan di area luar ruangan yang berada di sekitar gedung Smart Automation Workshop Politeknik Elektronika Negeri Surabaya, tepatnya di sekitar ruang 07.03, dengan mempertimbangkan aspek keamanan, aksesibilitas, dan representasi kondisi udara lingkungan sekitar. Selanjutnya, proses pengumpulan, pengolahan, serta analisis data dilakukan secara daring menggunakan laptop sebagai bagian dari pengembangan sistem dan analisis hasil penelitian.

4.4 Waktu Uji Coba

Uji coba pada penelitian ini dilaksanakan dalam rentang waktu Mei hingga Juni 2026. Pada periode tersebut dilakukan serangkaian tahapan penelitian yang meliputi pengambilan data kualitas udara menggunakan perangkat sensor, pengiriman dan penyimpanan data ke

sistem backend, pengolahan serta agregasi data, pengembangan dan pengujian dashboard berbasis web, hingga percobaan membuat model peramalan. Setiap tahapan dilaksanakan secara bertahap dan terstruktur sesuai dengan rancangan sistem yang telah ditetapkan, guna memastikan fungsi pemantauan dan prediksi kualitas udara dapat berjalan secara optimal dan menghasilkan informasi yang akurat.

4.5 Spesifikasi Peralatan Uji Coba

Untuk mendukung pelaksanaan uji coba sistem pemantauan dan prediksi kualitas udara, diperlukan peralatan dengan spesifikasi tertentu agar proses pengambilan data, pemrosesan, dan visualisasi dapat berjalan dengan baik. Spesifikasi perangkat yang digunakan mampu untuk melakukan pengolahan dan pengembangan sistem, serta infrastruktur pendukung jaringan. Rincian spesifikasi perangkat keras yang digunakan selama proses uji coba dan eksperimen disajikan pada Tabel 4.5.

Tabel 4.5 Spesifikasi Peralatan Uji Coba

No	Parameter	Spesifikasi
1	Perangkat	Laptop LOQ 15
2	Sistem Operasi	Windows 11 Home
3	Tipe Sistem	64-bit Operating System
4	Prosesor (CPU)	Intel® Core™ i5-12450HX @ 1.80 GHz (hingga 2.30 GHz)
5	Memori (RAM)	12 GB

4.6 Implementasi Arsitektur Sistem untuk Agregasi Data

Pada proyek ini, proses agregasi data tidak dilakukan secara langsung setiap kali data sensor diterima, melainkan dijalankan secara berkala untuk menjaga efisiensi sistem dan kestabilan kinerja. Pendekatan ini memungkinkan sistem mengelola volume data yang terus bertambah tanpa membebani proses pengambilan data utama. Oleh karena itu, diperlukan suatu mekanisme yang mampu menjalankan proses agregasi secara otomatis pada interval waktu tertentu sesuai dengan kebutuhan sistem

4.6.1 Implementasi *Ingestion Data* dan Perangkat IoT

Proses akuisisi data adalah fondasi krusial bagi seluruh sistem. Untuk memastikan integritas data dari sumbernya, dirancang sebuah arsitektur yang terdiri dari tiga lapisan utama: Sensor, API, dan Database. Arsitektur ini menjamin aliran data yang andal dari perangkat keras hingga penyimpanan cloud secara *real-time*.



Gambar 4.1 Alur Data Ingestion

1. Sensor Kualitas Udara: Sensor, yang terintegrasi dengan mikrokontroler seperti ESP32, adalah titik awal pengumpulan data. Secara berkala mengukur konsentrasi polutan (PM2.5, PM10, NO2, CO, O3) dan memformatnya, bersama dengan stempel waktu (timestamp) yang presisi, menjadi sebuah payload JSON. Timestamp ini menjadi kunci untuk semua analisis deret waktu selanjutnya.
2. API Ingestion Data: Payload JSON kemudian dikirimkan melalui protokol HTTP POST ke sebuah endpoint API. API ini berfungsi sebagai jembatan yang terstandarisasi antara perangkat keras dan infrastruktur cloud. Penggunaan API memberikan keunggulan krusial: memisahkan logika perangkat keras dari basis data, memungkinkan validasi data, dan menambahkan lapisan keamanan.
3. Supabase PostgreSQL: Lapisan terakhir adalah Supabase PostgreSQL, yang berfungsi sebagai penyimpanan permanen. Saat menerima payload JSON dari sensor, Supabase secara otomatis menyimpannya sebagai sebuah baris baru dalam tabel `tb_konsentrasi_gas`. Proses ini berjalan terus-menerus, memastikan database selalu diperbarui dengan data terkini dari lapangan.

Secara keseluruhan, alur kerja ini menciptakan *data pipeline* yang kokoh. Sensor mengumpulkan data, API memastikan transmisi yang aman dan terstruktur, dan Supabase menyediakan penyimpanan yang skalabel.

4.6.2 Spesifikasi dan Karakteristik Data

Sistem memanfaatkan beberapa sensor lingkungan dan gas untuk memperoleh parameter kualitas udara secara komprehensif, yaitu:

1. DHT22

Digunakan untuk mengukur suhu udara (°C) dan kelembapan relatif (%). Sensor ini

berfungsi sebagai parameter pendukung yang berpengaruh terhadap persepsi kualitas udara dan stabilitas sensor gas.

2. GP2Y1010AU0F

Merupakan sensor particulate matter (PM) yang digunakan untuk mendeteksi konsentrasi PM2.5 (dan estimasi PM10) dalam satuan $\mu\text{g}/\text{m}^3$. Sensor ini bekerja dengan prinsip optik berbasis hamburan cahaya.

3. MiCS-6814

Sensor gas multi-kanal yang digunakan untuk mendeteksi beberapa jenis gas, antara lain:

- CO (Carbon Monoxide)
- NO₂ (Nitrogen Dioxide)

4. MQ-131

Digunakan untuk mendeteksi ozon (O₃) di udara. Ozon merupakan polutan sekunder yang signifikan dalam penilaian kualitas udara ambien.

4.6.2.1 Mekanisme Pengiriman Data ke Backend

Sistem menggunakan komunikasi HTTPS berbasis REST API untuk mengirimkan data hasil pembacaan sensor ke backend Supabase. Setiap payload dikirim menggunakan metode HTTP POST dengan format JSON, disertai header autentikasi Supabase berupa apikey dan Authorization: Bearer.

4.6.2.2 Payload Data Konsentrasi Gas dan Lingkungan

Payload ini berisi data hasil konversi sensor ke satuan fisis ($\mu\text{g}/\text{m}^3$) serta parameter lingkungan dari DHT22. Format JSON yang dikirim adalah sebagai berikut:

```
{ "pm25_ugm3": 18.6,  
  "pm10_ugm3": 32.4,  
  "co_ugm3": 850.2,  
  "no2_ugm3": 42.7,  
  "o3_ugm3": 58.9,  
  "temperature": 29.4,  
  "humidity": 72.1 }
```

Keterangan:

- pm25_ugm3, pm10_ugm3 diperoleh dari sensor GP2Y1010AU0F


- co_ugm3, no2_ugm3 dari sensor MiCS-6814
- o3_ugm3 dari sensor MQ-131
- temperature dan humidity dari sensor DHT22

4.7 Hasil Eksperimen

Uji coba proyek akhir ini menghasilkan beberapa hasil eksperimen untuk mencapai tujuan yang telah didefinisikan.

4.7.1 Pengambilan Data dari Database

Proses inisialisasi dan pengambilan data diawali dengan melakukan koneksi terhadap Database yang telah terintegrasi dengan alat IoT. Selanjutnya, sistem memuat kredensial Supabase berupa *URL* dan *Role Key* dari berkas .env untuk menjaga keamanan akses, kemudian mendefinisikan struktur tabel dan kolom data sensor yang digunakan. Setelah dilakukan validasi terhadap kredensial yang tersedia, klien Supabase diinisialisasi sehingga sistem siap melakukan pengambilan data konsentrasi gas dan parameter lingkungan sebagai input pada tahap analisis dan pemodelan selanjutnya. Gambar 4.2 menunjukkan detail dari *logs* sebagai bukti pengambilan data dari python telah berhasil dilakukan.



Details	Raw
id	7d001d83-e763-4ebc-a607-a1eb2eb6e901
status	201
timestamp	16 Jun 26 13:03:08
method	POST
path	/rest/v1/tb_prediksi_kualitas_udara
search	
user_agent	ESP32HTTPClient

Gambar 4.2 Detail Logs Pengambilan Data

4.7.2 Preprocessing Data

Setelah berhasil melakukan pengambilan data dari Database, langkah yang dilakukan selanjutnya adalah *preprocessing*. Pada tahap ini dilakukan pengecekan nilai kosong atau *null* pada data mentah, jika terdapat baris yang mengandung nilai kosong maka akan langsung dilakukan penghapusan atau *drop*.

```

<class 'pandas.core.frame.DataFrame'>
DatetimeIndex: 27909 entries, 2026-05-15 16:2
Data columns (total 7 columns):
#   Column          Non-Null Count  Dtype
---  -
0   pm25_ugm3       27909 non-null  float64
1   pm10_ugm3       27909 non-null  float64
2   co_ugm3         27909 non-null  float64
3   no2_ugm3        27909 non-null  float64
4   o3_ugm3         27909 non-null  float64
5   temperature     27909 non-null  float64
6   humidity        27909 non-null  float64
dtypes: float64(7)
memory usage: 1.7 MB

```

Gambar 4.3 Hasil Preprocessing

4.7.3 Analisis Eksplorasi Data (EDA)

4.7.3.1 Karakteristik dan Ringkasan Statistik

Pada tahap ini, dilakukan analisis deskriptif terhadap *dataset* yang mencakup total 27.986 baris data pengamatan berfrekuensi tinggi tanpa adanya nilai kosong di seluruh parameter.

Tabel 4.6 Ringkasan statistik data


Metrik Statistik	PM2.5 ($\mu\text{g}/\text{m}^3$)	PM10 ($\mu\text{g}/\text{m}^3$)	CO ($\mu\text{g}/\text{m}^3$)	NO2 ($\mu\text{g}/\text{m}^3$)	O3 ($\mu\text{g}/\text{m}^3$)	Suhu ($^{\circ}\text{C}$)	Kelembapan (%)
Count	27,986	27,986	27,986	27,986	27,986	27,986	27,986
Mean	16.06	17.94	2923.69	0.11	22.46	34.68	59.83
Std	3.07	4.31	493.45	5.74	15.7	2.05	7.8
Min	8.02	7.71	918.37	0	1.08	29.6	26.4
Q25%	14.18	15.38	2610.66	0	19.63	33.5	56.4
Q50%	15.42	17.23	2928.03	0	19.63	34.6	61.2
Q75%	17.36	19.56	3244.52	0	19.63	34.9	65.3
Max	141.25	242.34	8237.73	309.59	140.42	47.6	98

Berdasarkan data statistik pada Tabel 4.6, polutan PM2.5 memiliki nilai rata-rata (*mean*) sebesar 16,06 dengan rentang deviasi yang relatif stabil = 3,07. Parameter PM10 menunjukkan rata-rata sebesar 17,94. Variabel bergerak pada tingkat rata-rata 2923,69 dengan nilai maksimum mencapai 8237,73 mengindikasikan adanya lonjakan polusi pada waktu-waktu tertentu akibat fluktuasi aktivitas antropogenik di sekitar


sensor. Sementara itu, parameter kondisi lingkungan mencatat rata-rata suhu udara yang cukup tinggi, yaitu 34,68 dengan kelembapan relatif berada di angka 59,8.

4.7.3.2 Analisis Tren Temporal dan Distribusi Polutan

Visualisasi deret waktu (*time series plot*) pada Gambar 4.4 dan visualisasi grafik rata-rata bergerak (*rolling mean* dengan *window* MA-5 dan MA-30) pada Gambar 4.5 digunakan untuk mereduksi *noise* berfrekuensi tinggi serta mengamati pergerakan tren jangka panjang polutan dari pertengahan Mei hingga Juni 2026.




Gambar 4.4 Visualisasi time series



Gambar 4.5 Visualisasi rolling mean


Secara umum, ketiga polutan berada pada level dasar (*baseline*) yang stabil, namun terdapat beberapa lonjakan ekstrem (*spikes*). Lonjakan paling signifikan pada PM2.5 mencapai 141,25 dan PM10 mencapai 242,34 terjadi secara simultan di sekitar tanggal 30 Mei 2026. Pengamatan sebaran frekuensi melalui plot histogram pada Gambar 4.6 menegaskan bahwa distribusi PM 2.5 dan PM10 terkonsentrasi padat di sekitar nilai rata-ratanya (*right-skewed* akibat keberadaan pencilan ekstrem), sedangkan distribusi CO membentuk kurva yang lebih mendekati distribusi normal (*bell-shaped*) di rentang 2000 hingga 4000.



Gambar 4.6 Histogram Sebaran Polutan

4.7.3.3 Analisis Pola Diurnal (Harian) Polutan

Analisis menggunakan *boxplot* per jam (0–23 WIB) pada Gambar 4.7 memperlihatkan karakteristik perilaku harian polutan yang unik:



Gambar 4.7 Boxplot Pola Harian


- PM2.5 dan PM10 menunjukkan pola fluktuasi yang mirip, dengan sebaran data yang cenderung mengecil pada jam-jam siang hari (jam 11–16) dan sedikit meningkat dengan variabilitas pencilan (*outliers*) yang lebih tinggi pada tengah malam hingga dini hari (jam 22–03).
- Karbon Monoksida (CO) menampilkan pola diurnal yang berkorelasi kuat dengan siklus aktivitas perkotaan (*rush hour*). Konsentrasi CO mulai

merangkak naik sejak pagi hari, mencapai puncaknya pada rentang jam 09.00 hingga 11.00 WIB, kemudian melandai secara bertahap, dan kembali mengalami kenaikan sekunder pada malam hari di sekitar jam 19.00 hingga 21.00 WIB.

4.7.4 Analisis Hubungan Antar Variabel (Korelasi)

4.7.4.1 Matriks Korelasi Pearson

Matriks korelasi digunakan untuk mengukur kekuatan hubungan linear antar parameter polutan dan faktor meteorologi. Hasil analisis menunjukkan hubungan korelasi positif yang sangat kuat antara PM2.5 dan PM10 dengan koefisien sebesar $r = 0,70$. Hubungan linear ini dipertegas oleh grafik *scatter plot* pada Gambar 4.8 yang menunjukkan pola kemiringan linier searah secara linear.




Gambar 4.8 Korelasi Pearson

Sebaliknya, polutan gas CO menunjukkan hubungan korelasi negatif yang lemah terhadap PM2.5 ($r = -0,22$) dan PM10 ($r = -0,21$). Untuk parameter meteorologi, ditemukan hubungan korelasi negatif kuat antara suhu dan kelembapan ($r = -0,72$), di mana peningkatan suhu lingkungan diikuti secara signifikan oleh penurunan kelembapan udara sekitar sensor.

4.7.4.2 Analisis Korelasi Silang (*Cross-Correlation Function - CCF*)

Untuk melihat hubungan ketergantungan antar variabel pada dimensi pergeseran waktu (*lag*), analisis CCF dilakukan hingga batas rentang 60 menit ke belakang:



Gambar 4.9 Visualisasi Cross Correlation Function

- CCF PM2.5 vs PM10: Hubungan korelasi silang berada di level tertinggi ($>0,65$) pada *lag* awal (0–5 menit) dan menurun secara sangat lambat hingga *lag* 60. Hal ini menandakan adanya kesamaan sumber emisi partikulat padat secara *real-time*.
- CCF PM2.5 vs CO & PM10 vs CO: Kedua pasangan ini menunjukkan nilai korelasi silang negatif yang konsisten stabil di sekitar -0,20 di sepanjang *lag* 0 hingga 60 menit, membuktikan tidak adanya efek penundaan waktu (*time-lagged effect*) yang mengubah karakteristik hubungan antara gas CO dan partikulat debu halus.

4.7.5 Uji Stasioneritas dan Analisis Autokorelasi

4.7.5.1 Uji Stasioneritas (Augmented Dickey-Fuller)

Berdasarkan pengujian statistik menggunakan ADF, didapatkan hasil bahwa ketiga target polutan telah memenuhi syarat dasar pemodelan deret waktu tanpa memerlukan proses *differencing* tambahan. Nilai statistik uji ADF untuk ketiga polutan menunjukkan signifikansi yang sangat tinggi:

Tabel 4.7 Hasil Uji ADF


Parameter Polutan	Nilai ADF Statistic	Nilai Ambang (p-value)	Ambang Batas (α)	Status
PM2.5	-7.5887	< 0.0001	0.05	STASIONER
PM10	-8.2093	< 0.0001	0.05	STASIONER
CO	-4.6148	0.000121	0.05	STASIONER

Berdasarkan data pada Tabel 4.7, pengujian stasioneritas dilakukan secara formal menggunakan metode statistik *Augmented Dickey-Fuller* (ADF) terhadap tiga variabel target utama peramalan. Hipotesis nol H_0 pada uji ini menyatakan bahwa data deret waktu memiliki akar unit (*unit root*) atau bersifat tidak stasioner.

Hasil komputasi menunjukkan nilai *p-value* untuk variabel PM2.5 dan PM10 berada di angka $< 0,0001$, sedangkan variabel CO berada di angka 0,000121. Karena nilai probabilitas (*p-value*) dari ketiga parameter polutan tersebut jauh lebih kecil dari ambang batas signifikansi $\alpha = 0,05$, maka terdapat bukti empiris yang sangat kuat untuk menolak H_0 dan menerima hipotesis alternatif (H_1). Dengan demikian, dapat disimpulkan secara definitif bahwa ketiga data deret waktu polutan tersebut bersifat stasioner pada tingkat level asli (*original level data*), sehingga aman dan layak untuk diintegrasikan secara langsung ke dalam model *machine learning* (XGBoost dan LightGBM) tanpa memerlukan proses transformasi *differencing* tambahan.

4.7.5.2 Analisis ACF dan PACF Multi-Polutan

Grafik ACF untuk PM2.5, PM10, dan CO pada Gambar 4.10 menunjukkan pola penurunan yang sangat lambat (*slow decay*) secara konsisten melintasi batas signifikansi hingga *lag* 60 menit. Pola ACF yang melandai lambat ini merupakan karakteristik khas data beresolusi tinggi (per menit) yang memiliki ketergantungan temporal jangka panjang (*long-term memory dependency*).



Gambar 4.10 Visualisasi ACF dan PACF

Grafik PACF untuk ketiga polutan menunjukkan pola terputus yang ekstrem (*die out* atau *sharp cut-off*) setelah *lag* ke-1 atau ke-2. Nilai PACF pada *lag* 1 berada di level tertinggi ($>0,65$), dan langsung menurun drastis mendekati batas nol pada *lag-lag* berikutnya. Karakteristik PACF ini mendasari keputusan penting dalam tahap *feature engineering* model regresi pohon (XGBoost & LightGBM), di mana penggunaan komponen fitur lag 1 menit akan menjadi prediktor paling dominan dan kritis dalam menentukan akurasi hasil peramalan 60 menit ke depan

4.7.6 Hasil Implementasi Model Peramalan

Evaluasi performa model peramalan dilakukan untuk mengukur tingkat akurasi algoritma dalam memproyeksikan konsentrasi polutan pada cakupan jangka pendek (*horizon* 60 menit). Dalam konteks pemantauan kualitas udara yang bersifat dinamis, pemilihan metrik evaluasi yang tepat sangat krusial untuk mencerminkan responsivitas model terhadap fluktuasi data lapangan. Oleh karena itu, evaluasi model didasarkan pada metrik *Mean Absolute Percentage Error* (MAPE) dan *Mean Absolute Error* (MAE).

Pemilihan metrik MAPE dan MAE sebagai parameter evaluasi utama didasarkan pada karakteristik data lingkungan yang memiliki variansi tinggi dan rentan terhadap lonjakan data (*spikes*). Metrik MAPE memberikan gambaran persentase kesalahan relatif yang sangat intuitif dalam menilai keandalan model di seluruh rentang nilai konsentrasi polutan, sedangkan MAE memberikan estimasi rata-rata besaran absolut kesalahan prediksi dalam satuan konsentrasi yang sama ($\mu\text{g}/\text{m}^3$). Pendekatan ini dipilih untuk memastikan bahwa model yang diimplementasikan tidak hanya akurat secara statistik, tetapi juga memberikan interpretasi kesalahan yang konsisten dan relevan secara operasional bagi sistem *monitoring* lingkungan. Perbandingan performa antara algoritma *XGBoost*, *LightGBM*, dan *Prophet* dilakukan dengan menggunakan *dataset* uji yang terpisah, di mana setiap model diuji kemampuannya dalam menangkap tren fluktuasi data per-menit. Pengujian ini bertujuan untuk mengidentifikasi model dengan *error rate* paling minimal dalam memprediksi profil polusi udara pada titik pemantauan secara *real-time*.

4.7.6.1 Implementasi Model XGBoost

Tahap preprocessing dimulai dengan pengambilan data dari database Supabase menggunakan teknik pagination untuk menangani *dataset* berukuran besar secara efisien, dengan batch sebesar 1000 baris per iterasi dalam rentang waktu 30 hari terakhir. Setelah seluruh data terkumpul dalam DataFrame pandas, dilakukan konversi

tipe data dimana semua kolom numerik dikonversi menggunakan `pd.to_numeric()` dengan parameter `errors='coerce'`. Proses cleaning dilakukan dengan menghapus seluruh baris yang mengandung nilai kosong menggunakan `dropna()`.

Model XGBoost diimplementasikan sebagai arsitektur regresi pohon keputusan utama untuk memetakan hubungan non-linear dari fitur historis multivariat. Konfigurasi hiperparameter latih yang diterapkan meliputi `n_estimators=300` untuk membatasi jumlah tahapan boosting sekuensial, `max_depth=6` guna mengontrol kompleksitas pohon agar terhindar dari *overfitting*, serta `learning_rate=0.05` sebagai ukuran langkah konvergensi fungsi *loss*. Parameter yang digunakan ditampilkan pada Tabel 4.8 berikut:

Tabel 4.8 Parameter terbaik model XGBoost

Parameter	Nilai	Deskripsi
n_estimators	300	Jumlah iterasi boosting
max_depth	6	Kedalaman maksimum pohon
learning_rate	0.05	Laju pembelajaran model
subsample	0.8	Fraksi sampel data untuk setiap pohon
colsample_bytree	0.8	Fraksi fitur untuk setiap pohon
reg_alpha (L1)	0.1	Koefisien regularisasi L1 untuk mendorong fleksibilitas pembobotan.
reg_lambda (L2)	1.0	Koefisien regularisasi L2 untuk menjaga stabilitas pohon.

Model XGBoost menunjukkan performa yang cukup tinggi pada holdout test set dengan hasil evaluasi yang disajikan pada Tabel 4.9 berikut:

Tabel 4.9 Metrik Evaluasi Model XGBoost

Target Polutan	MAE	RMSE	MAPE
PM2.5	1.03	1.56	7.50%
PM10	1.3	1.78	9.00%
CO	171.37	225.06	6.36%

Berdasarkan Tabel 4.9, model XGBoost menunjukkan tingkat akurasi peramalan yang sangat impresif pada *holdout test set*. Berdasarkan evaluasi kinerja, nilai *Mean Absolute Percentage Error* (MAPE) tercatat konsisten berada di bawah ambang batas 10% untuk seluruh parameter, yakni 7,50% untuk PM2.5, 9,00% untuk PM10, dan yang paling menonjol sebesar 6,36% untuk parameter gas CO. Dalam standar evaluasi peramalan deret waktu, nilai MAPE di bawah 10% mengklasifikasikan model ini ke dalam kategori *highly accurate forecasting* (peramalan sangat akurat). Hal ini mengonfirmasi keandalan algoritma *gradient boosting* sekuensial dalam meredam pengaruh penciran ekstrem data lapangan perkotaan secara presisi, menjadikannya sangat andal untuk proyeksi fluktuasi polutan jangka pendek.

4.7.6.2 Implementasi Model LightGBM

Model LightGBM (*Light Gradient Boosting Machine*) diterapkan sebagai model pembanding berbasis *gradient boosting* pohon keputusan yang mengandalkan teknik pertumbuhan daun secara vertikal (*leaf-wise growth strategy*) dan *histogram-based splitting* untuk mempercepat efisiensi komputasi. Konfigurasi latih model ini menggunakan kombinasi hiperparameter optimal berupa `max_depth=6`, `n_estimators=100`, dan `learning_rate=0.1`. Parameter optimal yang diperoleh ditampilkan pada Tabel 4.10 berikut:

Tabel 4.10 Parameter terbaik model LightGBM

Parameter	Nilai	Deskripsi
Random_state	42	Seed untuk reproduibilitas
max_depth	6	Kedalaman maksimum pohon
learning_rate	0.1	Laju pembelajaran model
n_estimators	100	Jumlah iterasi boosting

Model LightGBM menunjukkan performa yang sangat baik pada holdout test set. Hasil evaluasi model disajikan pada Tabel 4.11 berikut:

Tabel 4.11 Metrik Evaluasi Model LightGBM

Target Polutan	MAE	RMSE	MAPE
PM2.5	1.68	2.39	13.75%
PM10	2.03	2.59	16.94%
CO	753.13	910.86	56.24%

Hasil pengujian pada Tabel 4.11 membuktikan bahwa LightGBM mampu memberikan performa prediksi yang memadai pada sektor polutan partikulat, dengan nilai MAPE sebesar 13,75% untuk PM2.5 dan 16,94% untuk PM10. Angka ini masih masuk dalam kategori peramalan yang baik. Namun, kinerja LightGBM mengalami penurunan yang sangat drastis saat memodelkan polutan gas CO, di mana tingkat kesalahannya melonjak signifikan hingga 56,24%. Tingginya persentase kesalahan ini dipicu oleh arsitektur pembelahan vertikal *leaf-wise* LightGBM yang cenderung terlalu sensitif terhadap akumulasi kesalahan rekursif jangka pendek pada parameter gas yang fluktuasinya sangat tajam akibat emisi lalu lintas.

4.7.6.3 Implementasi Model Prophet

Model Prophet digunakan sebagai representasi pendekatan statistik deret waktu *decomposable additive* untuk memisahkan komponen tren makro dan pengaruh musiman harian (*diurnal*) secara otomatis. Eksperimen dirancang secara paralel dengan membangun tiga skenario pemodelan terpisah formal, di mana masing-masing skenario menempatkan data polutan sebagai target tunggal (γ), serta memanfaatkan parameter cuaca lingkungan bertindak sebagai variabel eksogen tambahan (*extra regressors*). Kinerja evaluasi dari model Prophet dipaparkan pada Tabel 4.12.

Tabel 4.12 Metrik Evaluasi Model Prophet

Target Polutan	MAE	RMSE	MAPE
PM2.5	2.54	2.78	18.47%
PM10	3.71	4.04	24.66%
CO	1965.65	1986.77	59.39%

Model Prophet menghasilkan kinerja yang paling tidak akurat di antara seluruh model pembandingan yang diuji. Prophet mencatatkan nilai kesalahan persentase (MAPE) sebesar 18,47% untuk PM2.5 dan 24,66% untuk PM10. Keterbatasan model ini memuncak pada skenario peramalan parameter CO, di mana MAPE mencapai angka ekstrem 59,39%. Tingginya tingkat kesalahan relatif ini membuktikan bahwa landasan matematis Prophet, yang mengandalkan fungsi kontinuitas deret Fourier dengan asumsi pola musiman kaku, mengalami kegagalan fungsi adaptasi (*severe underfitting*) dalam menangkap riak dinamika polusi perkotaan Surabaya berfrekuensi per menit.

4.7.6.4 Perbandingan Performa Ketiga Model

Untuk memberikan gambaran komprehensif mengenai performa masing-masing model, dilakukan perbandingan metrik evaluasi dari ketiga algoritma yang telah dilatih. Hasil perbandingan disajikan pada Tabel 4.13 berikut:

Tabel 4.13 Perbandingan Metrik evaluasi ketiga model

Target Polutan	Model Peramalan	MAE	RMSE	MAPE	Ranking Kinerja
PM2.5	XGBoost	1.03	1.56	7.50%	1
PM2.5	LightGBM	1.68	2.39	13.75%	2
PM2.5	Prophet	2.54	2.78	18.47%	3
PM10	XGBoost	1.3	1.78	9.00%	1
PM10	LightGBM	2.03	2.59	16.94%	2
PM10	Prophet	3.71	4.04	24.66%	3
CO	XGBoost	171.37	225.06	6.36%	1
CO	LightGBM	753.13	910.86	56.24%	2
CO	Prophet	1965.65	1986.77	59.39%	3

Berdasarkan akumulasi metrik komparasi pada Tabel 4.13, hasil pengujian membuktikan keunggulan mutlak XGBoost atas LightGBM dan Prophet. XGBoost menjadi satu-satunya algoritma yang mampu mempertahankan nilai MAPE di bawah 10% untuk seluruh polutan, menjadikannya masuk dalam kategori peramalan tingkat tinggi. Perbedaan performa paling mencolok terlihat pada kemampuan model melacak polutan gas CO. Ketika LightGBM dan Prophet kehilangan arah dengan persentase

kesalahan di atas 56%, XGBoost mampu menekan tingkat kesalahan hingga 6,36%. Melalui pembuktian metrik persentase kesalahan ini, model XGBoost divalidasi sebagai basis utama analitik prediksi pada bagian *backend* sistem.

4.7.7 Implementasi Model Klasifikasi ISPU

Selain model peramalan untuk meramalkan konsentrasi polutan, sistem ini juga memerlukan model klasifikasi untuk menentukan kategori kualitas udara berdasarkan standar ISPU. Model klasifikasi digunakan untuk memberikan informasi yang lebih mudah dipahami oleh pengguna, yaitu berupa kategori kualitatif (Baik, Sedang, Tidak Sehat, Sangat Tidak Sehat, Berbahaya) selain nilai numerik konsentrasi polutan.

4.7.7.1 Implementasi Model Random Forest sebagai *Robustness Layer*

Sistem klasifikasi pada penelitian ini mengadopsi arsitektur *Machine Learning* yang minimalis namun dirancang khusus untuk kebal terhadap gangguan (*noise*). Input model didefinisikan secara langsung menggunakan 5 variabel konsentrasi polutan mentah (PM2.5, PM10, CO, NO₂, dan O₃ dalam µg/m³) tanpa rekayasa fitur tambahan. Model *Random Forest* dengan konfigurasi 500 pohon keputusan (*estimators*), kedalaman maksimal 14 (*max_depth*), dan *min_samples_leaf* 2 difungsikan secara eksklusif sebagai *robustness layer* (lapisan ketahanan) untuk mencegah perpindahan kategori kualitas udara yang melompat-lompat (*flickering*) akibat fluktuasi sensor di area batas kategori (*boundary smoothing*).

Tabel 4.14 Spesifikasi Model

Parameter	Nilai
Algoritma	Random Forest Classifier
n_estimators	500
max_depth	14
min_samples_leaf	2
Fitur Input	PM2.5; PM10; CO; NO ₂ ; O ₃
Target	Kategori ISPU
Metode	Synthetic Multivariate Normal
Simulasi Noise	Gaussian Noise 10%

Untuk mencegah terjadinya kebocoran data (*data leakage*), pemisahan data latih dan data uji dilakukan di awal dengan proporsi 75:25 (*stratified split*). Penyeimbangan kelas minoritas menggunakan distribusi *multivariate normal* hanya diinjeksikan secara eksklusif pada data latih. Selanjutnya, model dilatih dengan menyuntikkan *Gaussian noise* sebesar 10%.

Kinerja model kemudian dievaluasi menggunakan *test set* yang 100% merupakan data riil lapangan yang juga telah diberi injeksi *noise* 10%. Hasil pengujian membuktikan bahwa meskipun model dihadapkan pada sinyal sensor riil yang terkorupsi *noise*, *Random Forest* terbukti mampu mempertahankan nilai akurasi aktual yang sangat stabil di angka 82,27% dengan nilai F1-Score Makro sebesar 68,14%

4.7.7.2 Implementasi Model Pembanding dan Pengujian Ketahanan (*Drift Test*)

Sebagai bentuk evaluasi arsitektur sistem yang komprehensif, performa *Random Forest* diuji lebih lanjut melalui *Drift Test* progresif (simulasi fluktuasi *noise* 5% hingga 25%). Model ini dibandingkan secara langsung dengan algoritma *gradient boosting* terkemuka (*XGBoost* dan *LightGBM*) serta performa aturan *Breakpoint* (BP) ISPU deterministik sebagai *baseline*.

Metrik perbandingan bertumpu pada kurva degradasi performa (*graceful degradation*) yakni kemampuan model mempertahankan akurasi setinggi mungkin ketika persentase kerusakan sinyal dari sensor membesar.

Tabel 4.15 Komparasi Evaluasi Ketahanan Model terhadap Fluktuasi Sensor

Tingkat Paparan Noise	Random Forest	XGBoost	LightGBM	Breakpoint ISPU (Baseline)
5% Noise	88.40%	87.70%	86.80%	89.20%
10% Noise	83.00%	82.30%	81.90%	80.20%
15% Noise	77.00%	76.50%	76.00%	73.70%
20% Noise	72.30%	72.30%	72.70%	68.80%
25% Noise	69.30%	68.40%	68.40%	64.60%

Berdasarkan Tabel 4.15, pada kondisi gangguan sinyal minor (5%), pendekatan kaku *rule-based* (Breakpoint ISPU) sedikit lebih unggul (89,2%). Namun, ketika persentase anomali sensor membesar memasuki skenario ekstrem (*worst-case* 15% - 25%), kelemahan arsitektur deterministik terlihat jelas karena akurasinya anjlok secara drastis hingga 64,6%. Di sisi lain, seluruh model *Machine Learning* menunjukkan ketahanan yang jauh lebih baik.

4.7.7.3 Alasan Pemilihan Random Forest

Di antara ketiga algoritma yang diuji, *Random Forest* terbukti menjadi model yang paling resisten terhadap *noise* acak, memimpin dengan akurasi 69,3% pada skenario terburuk, mengungguli *XGBoost* dan *LightGBM* (keduanya berada di angka 68,4%).

Pemilihan *Random Forest* sebagai lapisan penstabil (*robustness layer*) didasarkan pada landasan teoretis arsitekturnya. Algoritma *Random Forest* menggunakan teknik *bagging* (pembentukan ribuan pohon secara paralel dan independen), yang secara inheren jauh lebih superior dalam meredam variansi (*variance*) dan toleran terhadap data bising (*noise*). Sebaliknya, *XGBoost* dan *LightGBM* menggunakan teknik *boosting* (membangun pohon secara sekuensial), sehingga memiliki kecenderungan untuk mempelajari *error* atau anomali pada data yang terkorupsi. Keseluruhan evaluasi ini memvalidasi bahwa *Random Forest* adalah algoritma yang paling memenuhi standar operasional instrumen *early warning* untuk mencegah *dashboard* memberikan sinyal alarm palsu di lapangan.

4.7.7.4 Perhitungan ISPU dan Penetapan Polutan Dominan

Indeks Standar Pencemar Udara (ISPU) dihitung berdasarkan konsentrasi masing-masing parameter polutan menggunakan rumus breakpoint sesuai peraturan Menteri Lingkungan Hidup dan Kehutanan Nomor 14 Tahun 2020.

$$I = \frac{I_a - I_b}{X_a - X_b} (X_x - X_b) + I_b$$

Keterangan:

- I = ISPU terhitung
- I_a = ISPU batas atas
- I_b = ISPU batas bawah


- X_a = Konsentrasi ambien batas atas ($\mu\text{g}/\text{m}^3$)
- X_b = Konsentrasi ambien batas bawah ($\mu\text{g}/\text{m}^3$)
- X_x = Konsentrasi ambien nyata hasil pengukuran ($\mu\text{g}/\text{m}^3$)

4.7.8 Hasil Aplikasi Dashboard Web

Hasil analisis disajikan melalui aplikasi web interaktif berbasis React yang terdiri dari halaman overview dan predict, memungkinkan akses yang lebih mudah dan efisien bagi pengguna.

4.7.8.1 Tampilan Overview


Gambar 4.11 menampilkan tampilan halaman Dashboard Overview yang menyajikan informasi *real-time* mengenai kondisi kualitas udara dan parameter meteorologi dalam bentuk visualisasi yang interaktif dan informatif. Halaman ini dirancang sebagai landing page utama yang memberikan ringkasan komprehensif tentang status kualitas udara terkini kepada pengguna.



Gambar 4.11 Tampilan Halaman Overview

Komponen utama *dashboard* pada Gambar 4.12 berupa lingkaran yang menampilkan kategori ISPU secara visual. *Gauge* ini terhubung dengan perhitungan deterministik ISPU *breakpoint* yang telah diperkuat oleh algoritma *Random Forest*

sebagai lapisan ketahanan (*robustness layer*). Pendekatan ini memastikan indikator visual tetap stabil dan tidak melompat-lompat memberikan peringatan palsu meskipun sensor mengalami fluktuasi pembacaan sesaat secara *real-time*. Tampilan *gauge* menunjukkan kategori (Baik, Sedang, Tidak Sehat, Sangat Tidak Sehat, Berbahaya) bersama dengan nilai ISPU dan polutan dominan. Di bawah lingkaran, terdapat rekomendasi kesehatan untuk kelompok sensitif dan masyarakat umum sesuai kategori yang ditampilkan.



Gambar 4.12 Tampilan Klasifikasi Kualitas Udara


Metric card pada Gambar 4.13 menampilkan lima kartu parameter polutan (PM2.5, PM10, NO₂, CO, O₃) dalam satu baris dengan desain berbasis warna sesuai kategori ISPU. Setiap kartu menunjukkan nilai ISPU terkini, indikator status (Aman/Berisiko), dan batas ideal masing-masing parameter. Desain interaktif memungkinkan pengguna mengklik kartu untuk melihat detail lebih lanjut.



Gambar 4.13 Tampilan Metric Card


Pada Gambar 4.14, terdapat tiga panel informasi: (1) Ringkasan PM2.5 yang menampilkan rata-rata PM2.5 beserta standar deviasi, nilai minimum, dan persentil untuk periode tertentu; (2) Kondisi Sensor yang menunjukkan pembacaan suhu dan kelembapan dari lingkungan sekitar sensor; serta (3) Data BMKG yang menyajikan informasi cuaca eksternal meliputi kondisi hujan, suhu, kelembapan, kecepatan dan arah angin dengan timestamp update terakhir. Bagian bawah halaman menampilkan grafik "Pola Harian (Agregasi Per Jam)" yang memvisualisasikan rata-rata konsentrasi polutan berdasarkan jam untuk mengidentifikasi pola temporal harian. Dashboard

dilengkapi dengan tombol refresh untuk memperbarui data secara manual dan timestamp pada pojok kanan atas yang menunjukkan waktu update terakhir.




Gambar 4.14 Panel Informasi Tambahan

Pada Gambar 4.15 menampilkan Visualisasi berupa line chart yang menampilkan pola variasi PM2.5 berdasarkan jam dalam sehari. Data dibedakan antara hari kerja (weekday) dan akhir pekan (weekend) untuk mengidentifikasi perbedaan perilaku polusi. Visualisasi ini membantu pengguna mengidentifikasi jam-jam dengan konsentrasi tertinggi untuk perencanaan aktivitas.



Gambar 4.15 Pola Harian data teragregasi

Gambar 4.16 menampilkan Plot Histogram yang berfungsi untuk menampilkan distribusi atau sebaran frekuensi nilai PM2.5 pada jam sibuk pagi (07:00–09:00 WIB) selama 7 hari terakhir. Grafik ini mengelompokkan data ke dalam beberapa rentang konsentrasi berdasarkan kategori IPU, sehingga memudahkan dalam melihat jumlah data pada setiap kategori. Dengan visualisasi ini, pengguna dapat dengan cepat mengidentifikasi rentang nilai yang paling dominan serta memperoleh gambaran umum kondisi kualitas udara pada periode waktu tertentu.




Gambar 4.16 Distribusi PM2.5 pada jam sibuk

Pada Gambar 4.17 menampilkan visualisasi berupa line chart multi-polutan menampilkan trend PM2.5 dan PM10 dalam periode waktu yang dapat dipilih (1 jam, 7 jam, 14 jam, 30 jam, atau 90 jam). Pengguna dapat memilih periode waktu melalui tombol toggle yang tersedia. Visualisasi ini memungkinkan analisis perubahan kualitas udara dalam berbagai skala waktu.



Gambar 4.17 Trend data agregasi


Pada Gambar 4.18 menampilkan heatmap kalender menampilkan konsentrasi PM2.5 dalam bentuk kalender tahunan dengan pewarnaan berdasarkan kategori ISPU. Setiap sel mewakili satu hari dengan warna yang menunjukkan tingkat kualitas udara hari tersebut. Visualisasi ini memberikan gambaran cepat tentang kualitas udara dalam periode tahunan.



Gambar 4.18 Heatmap Kalender Kontribusi PM2.5

Visualisasi density plot pada Gambar 4.19 menampilkan distribusi konsentrasi CO dalam bentuk density plot yang menunjukkan frekuensi kemunculan nilai-nilai CO pada berbagai tingkat. Plot ini membantu pengguna memahami pola sebaran konsentrasi CO secara lebih intuitif.


Semua komponen visualisasi dirancang dengan prinsip responsive design sehingga dapat diakses melalui berbagai ukuran layar. Data diperbarui secara *real-time* melalui teknologi Supabase *Real-time*, dan komponen chart menggunakan library Recharts untuk rendering yang optimal.



Gambar 4.19 Sebaran data CO ISPU

4.7.8.2 Tampilan Hasil Prediksi


Gambar 4.20 menampilkan Tab Statistik yang menyediakan visualisasi lanjutan untuk analisis data kualitas udara dan evaluasi model *machine learning*. Berikut adalah komponen visualisasi utama yang tersedia di tab ini:



Gambar 4.20 Halaman Forecast

Komponen utama Tab Forecast berupa area chart yang menampilkan prediksi nilai ISPU untuk PM2.5, PM10, dan CO dalam rentang waktu 1 jam ke depan (60 titik data dengan interval 1 menit). Area chart menggunakan warna berbeda untuk setiap polutan: ungu untuk PM2.5, hijau untuk PM10, dan oranye untuk CO. Visualisasi ini memungkinkan pengguna melihat pola prediksi dan perubahan nilai ISPU setiap parameter polutan secara bersamaan.


Komponen ini juga menampilkan kartu status terkini yang menunjukkan prediksi kualitas udara untuk 60 menit ke depan, termasuk kategori ISPU, nilai ISPU total, dan polutan dominan. Pengguna dapat melihat detail prediksi dalam bentuk chart atau tabel dengan tombol toggle yang disediakan.



Gambar 4.21 Prediksi Kualitas Udara


Gambar 4.22 menampilkan visualisasi khusus untuk prediksi PM2.5 yang membedakan antara data aktual (historical) dan data prediksi menggunakan warna dan style yang berbeda. Data aktual ditampilkan dengan area chart berwarna ungu solid, sedangkan data prediksi ditampilkan dengan area chart berwarna oranye dengan garis putus-putus. Pendekatan visual ini memudahkan pengguna membedakan mana data yang sudah terjadi dan mana proyeksi ke depan.

Side panel menampilkan nilai PM2.5 terkini dan prediksi 1 jam ke depan untuk informasi cepat.




Gambar 4.22 Peramalan PM 2.5 dalam 1 jam

Sama dengan visualisasi PM2.5, Gambar. 4.23 menampilkan prediksi PM10 dengan pembedaan antara data aktual dan prediksi. Data aktual ditampilkan dengan warna hijau zamrud, sementara prediksi menggunakan warna oranye dengan garis putus-putus.



Gambar 4.23 Peramalan PM10 dalam 1 jam

Komponen prediksi untuk polutan CO pada Gambar 4.24 menampilkan data aktual dalam warna kuning/amber dan prediksi dalam warna oranye. Visualisasi ini membantu pengguna memahami tren dan proyeksi konsentrasi CO.



Gambar 4.24 Peramalan CO dalam 1 jam

Tab Statistik ini dirancang untuk pengguna yang membutuhkan analisis lebih mendalam tentang data kualitas udara.

4.7.9 Hasil Pengambilan Sampel dan Analisis Klasifikasi Kualitas Udara

4.7.9.1 Pengambilan Sampel Data Spasial

Tahapan ini dilakukan untuk mengumpulkan data kualitas udara yang representatif dari beberapa karakteristik lingkungan berbeda di Kota Surabaya. Pengambilan data dilakukan pada tiga titik pemantauan yang memiliki aktivitas dan kondisi lingkungan yang berbeda, yaitu titik pemantauan Ngagel sebagai representasi area permukiman dan perdagangan, titik pemantauan Rungkut sebagai representasi area pendidikan dan perkotaan, serta titik pemantauan Margomulyo sebagai representasi area industri dan lalu lintas padat.

Pada setiap titik pemantauan, perangkat monitoring kualitas udara ditempatkan pada satu titik yang dianggap mampu merepresentasikan karakteristik lingkungan di wilayah tersebut. Pengambilan data dilakukan secara bergantian dengan memindahkan perangkat monitoring ke masing-masing lokasi pengamatan. Sebelum proses pengambilan data dimulai, perangkat dipastikan berada dalam kondisi stabil dan telah melalui proses pemanasan (heating) sensor untuk memperoleh hasil pengukuran yang lebih akurat.

Data yang dikumpulkan meliputi konsentrasi PM_{2.5}, PM₁₀, CO, NO₂, O₃, suhu, dan kelembapan udara yang direkam secara *real-time* menggunakan perangkat monitoring kualitas udara. Selanjutnya, data dari ketiga lokasi digunakan untuk menganalisis karakteristik kualitas udara pada masing-masing titik pemantauan serta sebagai dasar dalam pengembangan model prediksi kualitas udara.


Meskipun parameter NO₂ dan O₃ turut direkam selama proses pengambilan data, hasil pengamatan menunjukkan bahwa kedua parameter tersebut memiliki variasi nilai yang relatif kecil dibandingkan parameter PM_{2.5}, PM₁₀, dan CO. Kondisi ini

menyebabkan informasi yang diperoleh dari data NO_2 dan O_3 belum cukup untuk menggambarkan perubahan konsentrasi polutan secara signifikan. Oleh karena itu, analisis dan pemodelan pada penelitian ini lebih difokuskan pada parameter $\text{PM}_{2.5}$, PM_{10} , dan CO yang menunjukkan variasi data yang lebih jelas dan representatif terhadap perubahan kualitas udara di lokasi pengamatan.

Penelitian mengambil data kualitas udara pada titik pemantauan Ngagel pada pagi hari saat periode *rush hour*. Lokasi pengamatan dipusatkan di ruas Jalan Raya Ngagel, Wonokromo (Koordinat: -7.290305, 112.760404). Selama pengamatan, arus kendaraan terlihat cukup padat dengan dominasi kendaraan roda dua dan roda empat yang melintasi lokasi pengambilan data. Titik pemantauan ini memiliki karakteristik ruas jalan yang relatif sempit dengan dua arah lalu lintas serta bangunan yang saling berdekatan di sepanjang koridor jalan. Kondisi tersebut berpotensi memengaruhi sirkulasi udara di sekitar lokasi pengamatan. Gambar 4.25 menunjukkan lokasi pengambilan data pada titik pemantauan Ngagel



Gambar 4.25 Lokasi Ngagel




Gambar 4.26 Titik Lokasi Ngagel

Penelitian mengambil data kualitas udara pada titik pemantauan Rungkut pada siang hari, tepatnya di koridor Jalan Rungkut Madya (Koordinat: -7.332245, 112.789994). titik pemantauan ini memiliki ruas jalan yang lebih lebar serta area sekitar yang relatif lebih terbuka. Selama pengamatan, lalu lintas didominasi kendaraan pribadi, khususnya mobil dan sepeda motor yang melintas secara kontinu. Selain itu, kondisi cuaca pada saat pengambilan data cenderung panas dengan intensitas sinar matahari yang tinggi. Gambar 4.27 menunjukkan lokasi pengambilan data pada titik pemantauan Rungkut.



Gambar 4.27 Lokasi Rungkut




Gambar 4.28 Titik Lokasi Rungkut

Penelitian mengambil data kualitas udara pada titik pemantauan Margomulyo pada sore hari. Pengukuran difokuskan pada area persimpangan Jalan Margomulyo, Kecamatan Tandes (Koordinat: -7.258845, 112.682067). Selama pengamatan, arus kendaraan terlihat relatif lancar meskipun volume kendaraan yang melintas cukup tinggi. Kendaraan umumnya hanya mengalami perlambatan saat fase lampu merah berlangsung. Selain itu, kondisi angin pada saat pengambilan data teramati bertiup cukup kuat dibandingkan lokasi pengamatan lainnya. Gambar 4.29 menunjukkan lokasi pengambilan data pada titik pemantauan Margomulyo.



Gambar 4.29 Lokasi Margomulyo



*Gambar 4.30 Titik Lokasi
Margomulyo*

4.7.9.2 Perbandingan Distribusi Label Antar Wilayah

Berdasarkan hasil pelabelan menggunakan model ISPU Breakpoint, wilayah Ngagel didominasi oleh kategori "Sedang" sebesar 95% dengan 3 data (5%) masuk

kategori "Tidak Sehat". Hal ini menunjukkan kualitas udara di titik pemantauan Ngagel cenderung lebih buruk dibandingkan lokasi pengamatan lainnya.

Wilayah Rungkut hampir seluruh data berada pada kategori "Sedang" (98,3%), dengan hanya satu data yang masuk kategori "Baik". Kondisi ini menunjukkan kualitas udara relatif stabil namun belum mencapai kategori baik secara dominan.

Wilayah Margomulyo menunjukkan kualitas udara terbaik, dengan 88,3% data masuk kategori "Baik" dan sisanya kategori "Sedang". Tidak ditemukan data yang masuk kategori "Tidak Sehat".

Tabel 4.16 Distribusi Label tiap wilayah

Wilayah	Baik	Sedang	Tidak Sehat	Total
Ngagel	0 (0%)	59 (95%)	3 (5%)	60
Rungkut	1 (1.7%)	59 (98.3%)	0 (0%)	60
Margomulyo	53 (88.3%)	7 (12.9%)	0 (0%)	60

Kondisi ini diduga dipengaruhi oleh karakteristik lingkungan masing-masing wilayah. Ngagel merupakan titik pemantauan lalu lintas padat dengan ruas jalan relatif sempit dan bangunan yang berdekatan sehingga akumulasi polutan cenderung lebih tinggi. Rungkut memiliki ruas jalan yang lebih lebar dan area yang lebih terbuka meskipun masih dipengaruhi aktivitas industri dan kendaraan. Sementara itu, Margomulyo memiliki arus kendaraan yang relatif lancar saat pengambilan data sehingga konsentrasi polutan yang terukur lebih rendah.

4.7.9.3 Statistik Deskriptif Hasil Pengukuran Kualitas Udara

Berdasarkan Tabel 4.17, rata-rata nilai ISPU PM2.5 tertinggi terdapat pada wilayah Ngagel sebesar 65,12, diikuti Rungkut sebesar 54,17 dan Margomulyo sebesar 41,17. Hasil ini menunjukkan bahwa konsentrasi partikulat halus di Ngagel cenderung lebih tinggi dibandingkan dua lokasi lainnya. Tingginya nilai PM2.5 pada Ngagel diduga berkaitan dengan aktivitas lalu lintas yang padat pada jam sibuk pagi hari serta kondisi ruas jalan yang relatif sempit sehingga akumulasi polutan lebih mudah terjadi. Selain memiliki rata-rata tertinggi, Ngagel juga menunjukkan rentang nilai yang cukup besar dengan nilai maksimum mencapai 79,05. Sementara itu, Margomulyo memiliki

rata-rata PM2.5 terendah, mengindikasikan kondisi udara yang relatif lebih baik dibandingkan lokasi lainnya.

Tabel 4.17 Statistik Deskriptif PM2.5

Statistik	Ngagel (Pagi)	Rungkut (Siang)	Margomulyo (Sore)
n	60	60	60
Rata-rata	65.12	54.17	41.17
Minimum	54.31	50.12	29.83
Maksimum	79.05	60.94	54.98
Standar Deviasi	4.57	2.35	5.32

Berdasarkan Tabel 4.18, pola yang serupa juga terlihat pada parameter PM10. Ngagel memiliki rata-rata ISPU PM10 tertinggi sebesar 32,99, sedangkan Rungkut dan Margomulyo masing-masing sebesar 21,37 dan 13,80. Hasil ini menunjukkan bahwa wilayah Ngagel memiliki tingkat pencemaran partikulat kasar yang lebih tinggi dibandingkan lokasi lainnya. Tingginya PM10 di Ngagel dapat dikaitkan dengan aktivitas kendaraan bermotor yang intensif serta kemungkinan adanya debu jalan yang terangkat akibat kepadatan lalu lintas. Sebaliknya, Margomulyo menunjukkan nilai PM10 terendah sehingga kualitas udara berdasarkan parameter ini relatif lebih baik.

Tabel 4.18 Statistik Deskriptif PM10

Statistik	Ngagel (Pagi)	Rungkut (Siang)	Margomulyo (Sore)
n	60	60	60
Rata-rata	32.99	21.37	13.8
Minimum	23.97	17.23	8.17
Maksimum	50.92	28.15	19.79
Standar Deviasi	4.65	2.31	2.04

Berbeda dengan PM2.5 dan PM10, rata-rata nilai ISPU CO tertinggi ditemukan di wilayah Rungkut sebesar 20,61, diikuti Margomulyo sebesar 20,31 dan Ngagel sebesar 15,38. Hal ini menunjukkan bahwa konsentrasi karbon monoksida tidak selalu

mengikuti pola konsentrasi partikulat. Tingginya nilai CO di Rungkut kemungkinan berkaitan dengan aktivitas industri manufaktur dan kendaraan yang melintas di titik pemantauan tersebut. Meskipun demikian, seluruh nilai CO masih berada pada rentang kategori kualitas udara yang relatif baik berdasarkan hasil pelabelan yang diperoleh.

Tabel 4.19 Statistik Deskriptif CO

Statistik	Ngagel (Pagi)	Rungkut (Siang)	Margomulyo (Sore)
n	60	60	60
Rata-rata	57.45	51.09	47.99
Minimum	50.5	47.5	45.4
Maksimum	72.9	54.6	51.2
Standar Deviasi	5.57	2.02	1.6

4.7.9.4 Studi Kasus Analisis Spasial menggunakan Uji ANOVA

Sebagai bentuk evaluasi tambahan untuk menguji kapabilitas analitik sistem dalam menangkap variasi paparan emisi di lapangan, dilakukan studi kasus komparatif secara spasial dan temporal pada tiga lokasi pemantauan dengan tata guna lahan yang berbeda (Ngagel, Rungkut, dan Margomulyo). Untuk membuktikan signifikansi perbedaan rata-rata konsentrasi polutan (PM_{2.5}, PM₁₀, dan CO) secara spasial di ketiga titik tersebut, pengujian hipotesis dilakukan menggunakan metode *One-Way Analysis of Variance* (ANOVA). Hipotesis yang diuji dirumuskan sebagai berikut:

- H_0 : Tidak terdapat perbedaan rata-rata konsentrasi polutan yang signifikan antar wilayah pengamatan.
- H_1 : Terdapat minimal satu wilayah dengan rata-rata konsentrasi polutan yang berbeda secara signifikan.

Sebelum pengujian ANOVA dilakukan, data terlebih dahulu diuji menggunakan uji normalitas *Shapiro-Wilk* dan uji homogenitas varians *Levene*. Hasil pengujian menunjukkan bahwa beberapa kelompok data belum sepenuhnya memenuhi asumsi normalitas dan homogenitas varians. Uji *Levene* menunjukkan bahwa homogenitas varians tidak sepenuhnya terpenuhi pada beberapa parameter partikulat, sedangkan parameter CO masih menunjukkan varians antar kelompok yang homogen. Namun demikian, pengujian ANOVA tetap dilakukan karena jumlah sampel pada setiap

kelompok pengamatan relatif besar dan seimbang, yaitu sebanyak 60 sampel per wilayah. Dalam kondisi tersebut, metode ANOVA masih dianggap cukup robust terhadap pelanggaran asumsi parametrik berdasarkan Teorema Limit Pusat (*Central Limit Theorem*).

Tabel 4.20 Ringkasan Hasil Uji One-Way ANOVA

Target Polutan	Nilai Statistik-F	p-value ANOVA	Kesimpulan Hipotesis
PM2.5	529.3162	< 0.001	Signifikan
PM10	548.8682	< 0.001	Signifikan
CO	231.4541	<0.001	Signifikan

Hasil pengujian One-Way ANOVA pada Tabel 4.20 menunjukkan bahwa seluruh parameter polutan memiliki nilai signifikansi di bawah tingkat signifikansi $\alpha = 0,05$. Parameter PM2.5 menghasilkan nilai F-statistik sebesar 529,31 dengan p-value < 0,001. Parameter PM10 menghasilkan nilai F-statistik sebesar 548,86 dengan p-value < 0,001, sedangkan parameter CO menghasilkan nilai F-statistik sebesar 231,45 dengan p-value < 0,001.

Berdasarkan hasil tersebut, hipotesis nol (H_0) ditolak sehingga dapat disimpulkan bahwa terdapat perbedaan rata-rata konsentrasi polutan yang signifikan antara kawasan Ngagel, Rungkut, dan Margomulyo.

BAB 5

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan pengujian yang telah dilakukan pada penelitian Proyek Akhir mengenai pengembangan *dashboard real-time* untuk monitoring dan prediksi kualitas udara di Kota Surabaya, dapat ditarik beberapa kesimpulan sebagai berikut:

1. Sistem telah berhasil mengakuisisi data lingkungan berfrekuensi per menit secara stabil melalui perangkat IoT (ESP32) yang dikirim melalui REST API ke *database* Supabase. Tantangan pertumbuhan volume data mentah (lebih dari 27.000 baris dalam 30 hari) berhasil diatasi dengan implementasi otomasi *Edge Functions* berbasis *cron job*. Metode ini terbukti secara efisien melakukan agregasi ter-materialisasi per jam, sehingga mempercepat performa *query visualisasi* antarmuka web tanpa membebani memori sistem *dashboard*.
2. Implementasi algoritma *Random Forest* (500 *trees*) sebagai lapisan ketahanan (*robustness layer*) terbukti sukses menstabilkan logika keputusan sistem dari fluktuasi pembacaan data sensor IoT. Dengan membatasi input pada 5 fitur konsentrasi polutan murni ($\mu\text{g}/\text{m}^3$) dan melatih model menggunakan injeksi *noise* 10%, model berhasil mempertahankan akurasi aktual sebesar 82,3% dan F1-Score Makro 68,1% pada data lapangan.
3. Evaluasi ketahanan melalui uji degradasi (*Drift Test*) memvalidasi keandalan arsitektur *Machine Learning* dalam skenario terburuk (*worst-case*). Saat dihadapkan pada tingkat paparan anomali sensor ekstrem sebesar 25%, model menolak mengalami kegagalan total (*graceful degradation*) dan masih sanggup mempertahankan tingkat akurasi 69,3%. Hal ini mengonfirmasi kelayakan ekosistem ini untuk beroperasi sebagai instrumen *early warning* yang prediktif dan tidak goyah oleh gangguan teknis kelistrikan maupun kerusakan kalibrasi perangkat.
4. Dalam pengujian peramalan 60 menit ke depan, model regresi pohon berdasar struktur *level-wise* (*XGBoost*) membuktikan keunggulan komutasi mutlak dibandingkan *LightGBM* maupun model statistik murni (*Prophet*). *XGBoost* tervalidasi mampu menekan akumulasi kesalahan rekursif secara presisi, terbukti dari capaian metrik MAPE yang secara konsisten di bawah 10% ($\text{PM}_{2.5} = 7,50\%$, $\text{PM}_{10} = 9,00\%$, dan $\text{CO} = 6,36\%$). Sebaliknya, model dekomposisi aditif *Prophet* terbukti mengalami kegagalan

adaptasi (*severe underfitting*) terhadap riak fluktuasi data per-menit dengan tingkat kesalahan MAPE menembus 59,39% pada gas CO.

5. Implementasi studi kasus spasial berhasil memvalidasi kemampuan analitik sistem dalam mengidentifikasi perbedaan karakteristik kualitas udara antar wilayah pengamatan. Berdasarkan hasil pengujian One-Way ANOVA, seluruh parameter polutan menunjukkan nilai signifikansi di bawah $\alpha = 0,05$ sehingga hipotesis nol ditolak. Hasil tersebut menunjukkan bahwa terdapat perbedaan rata-rata konsentrasi polutan yang signifikan antara kawasan Ngagel, Rungkut, dan Margomulyo. Secara deskriptif, kawasan lalu lintas padat perkotaan (Ngagel) menunjukkan tingkat paparan partikulat PM_{2.5} yang lebih tinggi, sedangkan kawasan industri manufaktur (Rungkut) dan logistik alat berat (Margomulyo) cenderung memiliki konsentrasi gas CO yang lebih dominan akibat aktivitas operasional industri dan kendaraan berat.

5.2 Saran

Berdasarkan hasil penelitian yang telah dilakukan, beberapa saran yang dapat diberikan untuk pengembangan penelitian maupun sistem pada masa mendatang adalah sebagai berikut:

1. Penelitian selanjutnya disarankan melakukan penyempurnaan pada konfigurasi perangkat dan *wiring* sensor agar pengukuran parameter NO₂ dan O₃ dapat menghasilkan variasi data yang lebih representatif. Periode pengambilan data dapat diperpanjang serta mencakup lebih banyak lokasi pengamatan untuk memperoleh karakteristik kualitas udara yang lebih beragam di Kota Surabaya.
2. Perekaman *dataset* yang hanya berjalan selama 30 hari memiliki keterbatasan dalam mengenali siklus makro lingkungan. Disarankan agar sistem dibiarkan merekam data minimal selama satu siklus peralihan musim (6 bulan), sehingga fitur *lag* prediktif dapat dilatih untuk mengenali variasi tren curah hujan secara musiman.
3. Sistem dashboard dapat dikembangkan lebih lanjut dengan menambahkan fitur notifikasi dini (*early warning system*) dan rekomendasi tindakan berdasarkan hasil prediksi kualitas udara.

DAFTAR PUSTAKA

- [1] Ismiyati, D. Marlita, and D. Saidah, “Pencemaran Udara Akibat Emisi Gas Buang,” *J. Manajemen Transp. Logistik*, vol. 1, no. 3, pp. 241–248, 2014. [Online]. Available: <https://journal.itltrisakti.ac.id/index.php/jmtranslog/article/view/23/24>
- [2] L. Hurek, “BMKG Juanda Peringatkan Cuaca Ekstrem di Surabaya dan Jawa Timur hingga 23 Maret 2025,” *radarsurabaya.jawapos.com*. [Online]. Available: <https://radarsurabaya.jawapos.com/surabaya/775787714/bmkg-juanda-peringatkan-cuaca-ekstrem-di-surabaya-dan-jawa-timur-pada-hingga-23-maret-2025>. Accessed: Jun. 22, 2025.
- [3] IQAir, “World Air Quality Report 2023.” [Online]. Available: <https://www.iqair.com/world-most-polluted-cities>. [Accessed: Jun. 22, 2025].
- [4] A. Bekkar, B. Hssina, N. Abekiri, S. Douzi, and K. Douzi, “Real-time AIoT platform for monitoring and prediction of air quality in Southwestern Morocco,” *PLoS One*, vol. 19, no. 8, pp. 1–28, 2024, doi: 10.1371/journal.pone.0307214.
- [5] P. Dey, S. Dev, and B. S. Phelan, “BiLSTM-BiGRU: A Fusion Deep Neural Network for Predicting Air Pollutant Concentration,” in *Proc. Int. Geosci. Remote Sens. Symp. (IGARSS)*, 2023, pp. 5166–5169, doi: 10.1109/IGARSS52108.2023.10282742.
- [6] D. Chaniago and A. Zahara, “Indeks Standar Pencemar Udara (ISPU) sebagai Informasi Mutu Udara Ambien di Indonesia.” [Online]. Available: <https://ditppu.menlhk.go.id/portal/read/indeks-standar-pencemar-udara-ispu-sebagai-informasi-mutu-udara-ambien-di-indonesia>. Accessed: Jun. 22, 2025.
- [7] M. Kusnandar, “Permen LHK Nomor 14 Tahun 2020 tentang Indeks Standar Pencemar Udara,” pp. 1–16, 2020.
- [8] J. Pebralia, H. Akhsan, and I. Amri, “Implementasi Internet of Things (IoT) dalam Monitoring Kualitas Udara pada Ruang Terbuka,” *J. Kumparan Fis.*, vol. 7, no. 1, pp. 1–8, 2024, doi: 10.33369/jkf.7.1.1-8.

- [9] A. Octaviano, S. Sofiana, D. O. Agustino, and P. Rosyani, “Pemantauan Kualitas Udara Berbasis Internet of Things,” *KLIK: Kajian Ilm. Inform. dan Komput.*, vol. 3, no. 2, pp. 147–156, 2022. [Online]. Available: <https://djournals.com/klik>
- [10] T. Chen and C. Guestrin, “XGBoost: A Scalable Tree Boosting System,” in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2016, pp. 785–794, doi: 10.1145/2939672.2939785.
- [11] Y. Özüpak and F. Alpsalaz, “Air Quality Forecasting Using Machine Learning: Comparative Analysis and Ensemble Strategies for Enhanced Prediction,” *Water, Air, Soil Pollut.*, vol. 236, no. 7, pp. 1–17, 2025, doi: 10.1007/s11270-025-08122-8.
- [12] J. Andrés and O. Mantilla, “Concentrations Using XGBoost and LightGBM Algorithms: A Case Study in Lima, Peru,” pp. 183–206, 2024.
- [13] G. Ke et al., “LightGBM: A Highly Efficient Gradient Boosting Decision Tree,” in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, 2017, pp. 1–9.
- [14] S. Tırınk, “Machine Learning-Based Forecasting of Air Quality Index under Long-Term Environmental Patterns: A Comparative Approach with XGBoost, LightGBM, and SVM,” pp. 1–21, 2025, doi: 10.1371/journal.pone.0334252.
- [15] Z. Zhang, S. Zhang, C. Chen, and J. Yuan, “A Systematic Survey of Air Quality Prediction Based on Deep Learning,” *Alexandria Eng. J.*, vol. 93, pp. 128–141, 2024, doi: 10.1016/j.aej.2024.03.031.
- [16] L. Mampitiya, N. Rathnayake, and Y. Hoshino, “Performance of Machine Learning Models to Forecast PM10 Levels,” *MethodsX*, vol. 12, p. 102557, 2024, doi: 10.1016/j.mex.2024.102557.
- [17] “Decoding PM2.5 Prediction in Nanning Urban Area, China: Unraveling Model Superiorities and Drawbacks,” 2025.
- [18] R. E. Walpole, R. H. Myers, and S. L. Myers, *Probability and Statistics for Engineers and Scientists*, 9th ed. Boston, MA, USA: Pearson.
- [19] “PM2.5 Concentration Prediction Based on LightGBM Optimized by Adaptive Multi-Strategy Enhanced Sparrow Search Algorithm,” 2023.

- [20] S. I. Purwaningrum, Pemantauan Kualitas Udara. Bandung, Indonesia: Widina Media Utama, 2024.

LAMPIRAN

Dataset Sampel

id	created_at	pm25_ugm3	pm10_ugm3	co_ugm3	no2_ugm3	o3_ugm3	temperature	humidity
4	2026-06-10 01:05:54.483961	25.11	31.41	1690.72	0	19.63	30.5	72.9
5	2026-06-10 01:06:54.030364	28.64	32.57	1606.4	0	19.63	30.6	72.3
6	2026-06-10 01:07:55.837918	26.17	33.5	1608.44	0	19.63	30.9	71.8
7	2026-06-10 01:08:57.217019	26.17	42.32	1489.56	0	19.63	31.1	70.2
8	2026-06-10 01:09:58.537479	35.33	36.52	1508.28	0	19.63	31.4	69.3
9	2026-06-10 01:10:59.560795	30.22	36.52	1465.85	0	19.63	31.7	66.7
10	2026-06-10 01:12:00.817427	26.87	30.94	1299.66	0	19.63	32	65.6
11	2026-06-10 01:13:01.885353	24.93	30.71	1376.27	0	19.63	32.3	63.7
12	2026-06-10 01:14:03.474985	31.1	33.03	1199.01	0	19.63	32.5	63.2
13	2026-06-10 01:15:04.961537	24.93	30.94	1293.38	0	19.63	32.8	62.3
14	2026-06-10 01:16:06.502611	25.11	29.55	1268.61	0	19.63	33.1	62.9
15	2026-06-10 01:17:07.399217	24.23	30.71	1248.9	0	19.63	33.3	62.2
16	2026-06-10 01:18:08.472515	24.23	28.15	1213.44	0	19.63	33.6	61.1
17	2026-06-10 01:19:09.375423	25.82	31.41	1244.4	0	19.63	33.8	60.6
18	2026-06-10 01:20:10.693068	24.76	29.78	1250.4	0	19.63	34	59.7

Tabel Hasil Uji Shapiro-Wilk

Polutan	Lokasi	Statistik Shapiro-Wilk	p-value	Kesimpulan
PM2.5	Margomulyo	0.9062	0.0002	Tidak Normal
PM2.5	Ngagel	0.9595	0.0444	Tidak Normal
PM2.5	Rungkut	0.9588	0.0410	Tidak Normal
PM10	Margomulyo	0.9312	0.0022	Tidak Normal
PM10	Ngagel	0.9281	0.0016	Tidak Normal
PM10	Rungkut	0.9603	0.0489	Tidak Normal
CO	Margomulyo	0.9716	0.1753	Normal
CO	Ngagel	0.8229	0.0000	Tidak Normal

Tabel Hasil Uji Homogenitas Varians Levene

Polutan	Statistik Levene	p-value	Kesimpulan
PM2.5	10.6000	0.000044870564793	Tidak Homogen
PM10	12.1480	0.000011382024902	Tidak Homogen
CO	0.2445	0.78336020141	Homogen

BIODATA



Data Pribadi

Nama	: Muhammad Yusuf Rajabiyah
Tempat/Tanggal Lahir	: Gresik, 1 September 2003
Program Studi	: Sains Data Terapan
Alamat	: Jl. Nyai Ageng Arem-arem VI/01, Gresik
Telepon/HP	: (+62) 896-9936-0314
Motto	: “Gaungan keras tanpa kerja nyata hanyalah sebuah kebisingan tanpa makna”

Riwayat Pendidikan

- | | |
|--|-------------------|
| ● SD Negeri 1 Sidokumpul Gresik | Tahun 2010 – 2016 |
| ● SMP Negeri 2 Gresik | Tahun 2016 – 2019 |
| ● SMA Nahdlatul Ulama 2 Gresik | Tahun 2019 – 2022 |
| ● Politeknik Elektronika Negeri Surabaya | Tahun 2022 – 2026 |

